

BỘ KHOA HỌC VÀ CÔNG NGHỆ
HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG



ĐỒ ÁN **TỐT NGHIỆP ĐẠI HỌC**

***Đề tài:* PHÁT TRIỂN MÔ HÌNH AI PHÁT HIỆN VÀ CHẨN ĐOÁN LỖI
PHÁT ÂM TIẾNG ANH SỬ DỤNG PHƯƠNG PHÁP THUẦN GỢI Ý.**

Người hướng dẫn : TS. Trần Tiến Công

Sinh viên thực hiện : Lê Phan Nhật Minh – B21DCVT033
Nguyễn Phú Tùng Anh – B21DCVT062

Hệ : Đại học chính quy

Hà Nội, 2026

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Điểm: (Bằng chữ:)

Hà Nội, ngày tháng năm 20...
Giảng viên hướng dẫn

NHẬN XÉT CỦA GIẢNG VIÊN PHẢN BIỆN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Điểm: (Bằng chữ:)

Hà Nội, ngày tháng năm 20...

Giảng viên phản biện

LỜI CẢM ƠN

Lời đầu tiên, nhóm chúng em xin gửi lời cảm ơn chân thành và sâu sắc đến TS. Trần Tiến Công đã trực tiếp hướng dẫn, tận tình chỉ bảo và đưa ra những góp ý chi tiết, tâm huyết giúp nhóm hoàn thiện đồ án này một cách tốt nhất.

Chúng em cũng xin bày tỏ lòng biết ơn tới các thầy cô tại Học viện Công nghệ Bưu chính Viễn thông, đặc biệt là các thầy cô thuộc chuyên ngành Trí tuệ nhân tạo, hệ Chất lượng cao, khoa Công nghệ thông tin 1. Những kiến thức, kỹ năng và kinh nghiệm quý báu mà thầy cô truyền đạt trong suốt bốn năm qua không chỉ là hành trang quan trọng cho sự nghiệp tương lai, mà còn là động lực để chúng em không ngừng trau dồi và hoàn thiện bản thân.

Chúng em cũng xin gửi lời cảm ơn chân thành tới trung tâm Vuihoc.vn đã đồng ý cung cấp bộ dữ liệu ghi âm, góp phần quan trọng trong việc nâng cao chất lượng và hiệu quả của mô hình AI mà chúng em phát triển.

Cuối cùng, chúng em xin gửi lời cảm ơn chân thành tới gia đình và bạn bè đã luôn đồng hành, động viên và là chỗ dựa vững chắc trong suốt quá trình học tập tại Học viện.

Mặc dù đã rất cố gắng nhưng do hạn chế về kinh nghiệm, đồ án khó tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự chỉ dẫn và đóng góp ý kiến từ quý thầy cô để đề tài được hoàn thiện hơn.

Chúng em xin chân thành cảm ơn!

Hà Nội, ngày 29 tháng 12 năm 2025
Sinh viên

Lê Phan Nhật Minh
Nguyễn Phú Tùng Anh

MỤC LỤC

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT	iv
DANH MỤC HÌNH VẼ	v
DANH MỤC BẢNG BIỂU	vi
PHẦN MỞ ĐẦU	vii
1 TỔNG QUAN ĐỀ TÀI	1
1.1 Các phương pháp đã được phát triển hiện nay trong lĩnh vực	3
1.1.1 Phương pháp dựa trên chấm điểm	3
1.1.2 Mô hình thuần chính tả (Dictation-based model)	6
1.1.3 Mô hình thuần gợi ý (Prompt-based model)	8
1.1.4 Nhận xét chung	9
2 MỤC TIÊU, ĐỊNH HƯỚNG VÀ GIẢI PHÁP	11
2.1 Mục tiêu hệ thống	11
2.2 Định hướng giải pháp tổng thể	11
2.3 Kỳ vọng hệ thống	11
2.4 Các kiến trúc và hệ thống được sử dụng	12
2.4.1 Mạng nơ-ron nhiều lớp (Multilayer Perceptron – MLP)	12
2.4.2 Mạng nơ-ron tích chập (Convolutional Neural Network – CNN)	15
2.4.3 Mạng bộ nhớ dài-ngắn hạn (Long Short-Term Memory – LSTM)	17
2.4.4 Cấu trúc Attention	21
2.4.5 Cấu trúc Transformer Encoder	25
2.4.6 Framework Wav2vec 2.0	26
3 XÂY DỰNG MÔ HÌNH VÀ HỆ THỐNG	28
3.1 Kiến trúc mô hình	28
3.1.1 Định nghĩa bài toán	28
3.1.2 Thành phần mô hình	28
3.2 Thu thập và xử lý dữ liệu	32
3.2.1 Yêu cầu đầu vào của mô hình	32
3.2.2 Các bộ dữ liệu được sử dụng	32
3.2.3 Tiền xử lý, phân tích và tăng cường dữ liệu	34
3.3 Thí nghiệm và kết quả	36
3.3.1 Cấu hình dữ liệu huấn luyện	36
3.3.2 Cấu hình mô hình	37
3.3.3 Kết quả thực nghiệm	37
3.4 Xây dựng hệ thống giao diện	39
3.4.1 Luồng yêu cầu và xử lý chính	39
3.4.2 Phân tích thiết kế	42

4 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	52
4.1 Kết luận	52
4.2 Hướng phát triển	52
5 PHỤ LỤC	54
5.1 Phụ lục A: Danh sách các âm vị trong chuẩn ARPABET	54
5.2 Phụ lục B: Thuật toán Needleman–Wunsch	55
5.3 Phụ lục C: Chi tiết cấu hình của mô hình PB-MDD-TA	59
TÀI LIỆU THAM KHẢO	62

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
AI	Artificial Intelligence – Trí tuệ nhân tạo
DL	Deep Learning – Học sâu
MDD	Mispronunciation Detection and Diagnosis – Hệ thống phát hiện và chẩn đoán lỗi phát âm
CAPT	Computer Assisted Pronunciation Training – Hệ thống hỗ trợ luyện phát âm bằng máy tính, sử dụng công nghệ xử lý tiếng nói và học máy để hỗ trợ người học cải thiện phát âm
CNN	Convolutional Neural Network – Mạng nơ-ron tích chập
RNN	Recurrent Neural Network – Mạng nơ-ron hồi quy
LSTM	Long Short-Term Memory – Mạng bộ nhớ dài-ngắn hạn, một biến thể của RNN được thiết kế để học các phụ thuộc dài hạn trong dữ liệu chuỗi
CTC	Connectionist Temporal Classification – Hàm mất mát phân loại theo thời gian cho phép huấn luyện mô hình chuỗi-sang-chuỗi mà không cần căn chỉnh nhãn theo từng khung thời gian
NLLLoss	Negative Log Likelihood Loss – Hàm mất mát log khả năng âm

DANH MỤC HÌNH VẼ

1	Các loại lỗi phát âm và những thông số khác phục vụ trong đánh giá phát âm	2
2	Kiến trúc mô hình chấm điểm CaGOP	4
3	Kiến trúc mô hình CNN–RNN–CTC	8
4	Kiến trúc mô hình PG–MDD	9
5	Ví dụ về phép toán tích chập với ma trận 3×3 và bộ lọc 2×2	16
6	Phép toán tích chập với phép đệm	16
7	Phép toán tích chập với bước nhảy là 3 cho chiều cao và 2 cho chiều rộng	17
8	Ví dụ về gộp tối đa với bộ lọc kích thước 2×2	17
9	Một mạng RNN với trạng thái ẩn	18
10	Cấu trúc của một khối LSTM	19
11	Khối Bi-LSTM	20
12	Scaled Dot-Product Attention	22
13	Tích vô hướng (Dot-Product) giữa các vector Truy vấn (Query) và Khóa (Key)	23
14	Tích vô hướng (Dot-Product) giữa các ma trận Truy vấn (Query) và Khóa (Key)	23
15	Phép nhân ma trận giữa ma trận attention weight A và ma trận giá trị V	24
16	Sự khác biệt giữa nguồn đầu vào của các ma trận Query, Key và Value trong cơ chế self-attention và cross-attention	24
17	Multi-head Attention	25
18	Cấu trúc Transformer Encoder	26
19	Cấu trúc framework wav2vec 2.0	26
20	Sơ đồ cấu trúc mô hình PB-MDD-TA	31
21	Phương pháp tạo dãy đánh dấu lỗi sử dụng thuật toán căn chỉnh Needleman–Wunsch. Câu đối chiếu: “She turned in at the hotel”.	35
22	Bảng phân bố tần suất lỗi phát âm trong bộ dữ liệu L2-ARCTIC.	35
23	Luồng xử lý hệ thống	39
24	Sơ đồ phạm vi hệ thống	42
25	Biểu đồ use case tổng quát	44
26	Giao diện đăng nhập	47
27	Bảng thống kê dữ liệu đầu ra của mô hình	48
28	Giao diện nhập âm thanh và câu gốc	49
29	Giao diện kết quả phân tích	50
30	Tooltip phân tích chi tiết âm vị và điểm số	51

DANH MỤC BẢNG BIỂU

1	<i>Các hàm kích hoạt phổ biến trong mạng nơ-ron và đặc điểm của chúng</i>	13
2	<i>Kết quả kiểm tra qua các phiên bản mô hình được phát triển</i>	38
3	<i>So sánh kết quả kiểm tra của mô hình PB-MDD-TA với các mô hình hiện tại</i>	39

PHẦN MỞ ĐẦU

Đặt vấn đề: Hiện nay, nhu cầu học ngoại ngữ, đặc biệt là tiếng Anh, ngày càng gia tăng trong bối cảnh toàn cầu hóa, đặt ra thách thức lớn cho các cơ sở giáo dục trong việc tối ưu hóa nguồn lực giảng dạy và cung cấp phản hồi kịp thời, nhất quán cho số lượng lớn học sinh. Sự phát triển của trí tuệ nhân tạo (AI) và các mạng lưới nơ-ron học sâu (DNN) đã mở ra các giải pháp tự động hóa đánh giá và cá nhân hóa quá trình học tập, trong đó các mô hình nhận diện và chẩn đoán lỗi phát âm (Mispronunciation Detection and Diagnosis - MDD), giúp cải thiện hiệu quả giảng dạy và giảm tải cho giáo viên. Tuy các giải pháp hiện nay đã đạt được những tiến bộ rõ rệt so với những phương pháp thuật toán cổ điển, việc đạt được sự cân bằng giữa hiệu năng, tốc độ và độ chính xác vẫn là một vấn đề bất cập.

Giải pháp hiện tại và hạn chế: Các mô hình MDD đã được phát triển hiện nay thường sử dụng các kĩ thuật end-to-end, xây dựng dựa trên các phương pháp và đặc tính của lĩnh vực xử lý âm thanh lời nói và đã đạt được những kết quả rõ rệt. Tuy nhiên, các mô hình này mắc phải một số bất lợi như thiếu hụt dữ liệu huấn luyện của người học tiếng Anh không bản ngữ, mất cân bằng giữa hai chỉ số Precision và Recall, hay phụ thuộc nhiều vào kiến thức miền để tinh chỉnh thủ công.

Mục tiêu và định hướng giải pháp: Đề tài này hướng tới xây dựng một mô hình phát hiện và chẩn đoán lỗi phát âm dựa trên phương pháp học sâu end-to-end bằng cách sử dụng các kiến trúc căn bản như LSTM hay Transformer và tinh chỉnh mô hình Wav2Vec 2.0 cho tác vụ nhận diện âm vị. Bên cạnh đó, mô hình cũng được xây dựng với mức độ phụ thuộc tối thiểu vào kiến thức miền trong xử lý tiếng nói nhằm tập trung vào chứng minh hiệu năng của phương pháp end-to-end. Mô hình cũng được đóng gói và thử nghiệm trên hệ thống nhằm kiểm thử hiệu năng trong thực tế và thu tập dữ liệu trong quá trình suy luận.

Đồ án được bố cục theo 4 chương như sau:


- Chương 1: Cung cấp cái nhìn tổng quan về hệ thống phát hiện và chẩn đoán lỗi phát âm trong ứng dụng hỗ trợ giáo dục tiếng Anh, đồng thời khảo sát các kĩ thuật mới nhất đã được phát triển, cùng với điểm mạnh và điểm yếu của từng kĩ thuật
- Chương 2: Mục tiêu và định hướng giải pháp
- Chương 3: Xây dựng, kiểm tra mô hình, phân tích kết quả thu được và triển khai thực tế trên hệ thống
- Chương 4: Kết luận, tổng kết bài toán, tóm tắt kết quả đạt được, nêu ra những hạn chế của mô hình đã phát triển và hướng phát triển tiếp theo nhằm cải thiện kết quả đầu ra của mô hình

CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI

Hiện nay, xu hướng toàn cầu hóa đã dẫn đến sự gia tăng trong nhu cầu học ngoại ngữ, đặc biệt là tiếng Anh. Việc học ngoại ngữ không chỉ mang ý nghĩa về mặt giao tiếp quốc tế mà còn giúp học sinh tiếp cận tri thức toàn cầu, đồng thời nâng cao khả năng hội nhập của đất nước trong các lĩnh vực kinh tế, khoa học, công nghệ và văn hóa, từ đó cải thiện năng lực cạnh tranh của học sinh trong môi trường nghề nghiệp đa dạng. Trước thách thức này, các cơ sở giáo dục đã và đang phải tối ưu hóa thời gian, nguồn lực giảng dạy và khả năng cung cấp phản hồi chính xác cho từng học sinh, trong bối cảnh giáo viên phải đối mặt với khối lượng lớn học sinh và nhu cầu đánh giá hiệu quả học tập một cách nhanh chóng và nhất quán. Sự phát triển nhanh chóng của trí tuệ nhân tạo (AI) và các kiến trúc học sâu (DL) đã mở ra những giải pháp khả thi nhằm tự động hóa một phần quá trình giảng dạy và đánh giá, cho phép phân tích dữ liệu học tập của từng cá nhân và điều chỉnh nội dung, tốc độ, cũng như phương pháp giảng dạy phù hợp với năng lực riêng của học sinh. Các mạng nơ-ron sâu (DNN) hiện nay không chỉ có khả năng nhận diện lỗi trong bài phát âm, chữ viết tay hay câu trả lời mở mà còn có thể đưa ra các đánh giá định lượng, cung cấp phản hồi tức thì giúp học sinh nhận biết và điều chỉnh sai sót, đồng thời giảm gánh nặng đánh giá thủ công cho giáo viên. Nhờ vậy, các ứng dụng hỗ trợ học phát âm ngoại ngữ chuyên biệt, như hệ thống CAPT (Computer-aided Pronunciation Training), ngày càng được phát triển và triển khai, giúp học viên cải thiện kỹ năng phát âm một cách chính xác và hiệu quả, trong khi giáo viên vẫn có thể quản lý khối lượng học sinh lớn mà không làm giảm chất lượng giảng dạy.

Trong các lớp học ngoại ngữ truyền thống, phát âm thường được dạy qua phương pháp thầy đọc, trò lặp lại (teacher-led repetition), nghe và bắt chước âm chuẩn, hoặc qua luyện tập từng âm vị riêng lẻ. Học viên thường phải nghe giáo viên đọc mẫu, sau đó phát âm lại theo sự hướng dẫn, đôi khi kết hợp với việc ghi âm và tự nghe lại. Giáo viên chủ yếu đưa ra phản hồi trực tiếp, theo quan sát, nhấn mạnh vào độ chính xác của từng nguyên âm và phụ âm. Các nhược điểm chính của phương pháp này bao gồm việc giới hạn về thời gian phản hồi vì giáo viên không thể theo sát mọi học viên, hay thiếu dữ liệu định lượng để theo dõi tiến độ, và khó khăn trong việc đánh giá các đặc trưng siêu âm vị như trọng âm, nhịp điệu và ngữ điệu - những yếu tố vốn quan trọng để phát âm tự nhiên. Dựa trên ý tưởng lấp đầy những khoảng trống trong phương pháp giảng dạy truyền thống, cùng với sự khai thác mô hình ML/DNN và công nghệ nhận dạng giọng nói (Automatic Speech Recognition - ASR), nhiều nghiên cứu đã phát triển các hệ thống hướng dẫn phát âm điện tử (Computer Assisted Pronunciation Training - CAPT) nhằm cung cấp cho người học phản hồi tức thì và chính xác. Bên cạnh khả năng đánh giá độ chính xác của âm vị và chỉ ra những lỗi phát âm tiềm ẩn, hệ thống này còn có thể được mở rộng để lưu trữ dữ liệu phát âm của học viên nhằm phân tích tiến trình cá nhân, từ đó đưa ra các bài luyện tập cá nhân hóa.

Thông thường, CAPT hoạt động bằng cách nhận vào một đoạn âm thanh ghi âm biểu thị thông tin mà người dùng muốn truyền tải và chuỗi văn bản mục tiêu tương ứng, sau đó tiến hành xử lý và phân tích tín hiệu lời nói nhằm đưa ra các đánh giá định lượng (quantitative feedback) hay định tính (qualitative feedback) về mức độ chuẩn xác, tự nhiên hay và đúng đắn của phát âm. Các phản hồi này giúp người học nhận diện sai sót, điều chỉnh phát âm, đồng thời hỗ trợ cá nhân hóa quá trình rèn luyện. CAPT thường sử dụng cho các hình thức luyện tập nghe và nhắc lại (listen-and-repeat), đọc to (read-aloud), hoặc các bài tập nhận diện âm. Do vậy, để hệ thống CAPT đạt hiệu quả, điều kiện then chốt là phải có một mô-đun cốt lõi có khả năng nhận dạng âm vị và phát hiện lỗi phát âm một cách chính xác trong lời nói của người học, cũng như cung cấp nhận xét phù hợp. Mô-đun cốt lõi này được gọi là Mispronunciation Detection and Diagnosis (MD/MDD), hay Automatic Pronunciation Error Detection (APED) trong một số tài liệu, và được xem là thành phần trung tâm quyết định chất lượng của toàn bộ hệ thống CAPT [1].



Hình 1: Các loại lỗi phát âm và những thông số khác phục vụ trong đánh giá phát âm

Trong cách phát hiện lỗi phát âm của ngôn ngữ, các nghiên cứu thường chia ra hai loại lỗi chính. Lỗi âm vị (Phonetics errors / segmental errors) bao quát sự sai sót trong quá trình tạo lập các âm vị đơn lẻ, bao gồm nguyên âm và phụ âm. Ba dạng lỗi phổ biến nhất là thêm âm (insertion), thiếu âm (deletion) và nhầm âm (substitution) [2]. Các lỗi này thường xuất phát do ảnh hưởng tiêu cực của tiếng mẹ đẻ (negative transfer), sự chuyển đổi chữ-âm sai lệch (incorrect letter-to-sound mapping) hoặc việc đọc sai câu được gợi ý (misreading). Ví dụ cho negative transfer – nguồn lỗi phổ biến ở người Việt khi học tiếng Anh, trong tiếng Việt thường tồn tại các âm tiết mở và âm tiết đóng, nhưng chỉ có các phụ âm vô thanh /p/, /t/, /k/ và các âm mũi /m/, /n/, /ŋ/ được phép xuất hiện ở vị trí cuối âm tiết, trong khi đó tiếng Anh cho phép gần như tất cả các âm phụ âm xuất hiện ở cuối âm tiết. Do vậy, đối với người nói tiếng Việt, các từ như “good” (phiên âm: /gud/), với phụ âm dừng hữu thanh ở cuối âm tiết, có thể gây khó khăn khi phát âm; họ có thể thay thế phụ âm dừng hữu thanh bằng phụ âm dừng vô thanh, dẫn đến phát âm thành “goot” (phiên âm: /gut/) [3]. Lỗi siêu phân đoạn (Prosodic errors / supra-segmental errors) liên quan đến các đặc trưng ngữ điệu bao trùm toàn bộ từ hoặc câu, bao gồm trọng âm (stress), nhịp điệu (rhythm) và ngữ điệu (intonation), đây là các đặc trưng có ảnh hưởng quan trọng đến độ dễ hiểu (intelligibility), đặc biệt trong các ngôn ngữ thanh điệu, khi sự thay đổi trong cao độ có thể dẫn tới sự thay đổi trong nghĩa của từ. Trọng âm được tạo ra thông qua sự thay đổi về độ lớn, độ dài hoặc cao độ của âm tiết được nhấn và có thể ở cấp độ từ (syllable stress / lexical stress) hoặc cấp độ câu (sentence stress); do sự khác biệt trong hệ thống trọng âm giữa các ngôn ngữ, người học dễ gặp lỗi khi chuyển từ L1 sang L2. Nhịp điệu (rhythm) là mô hình nhấn nhá của các âm tiết trong một từ hoặc câu; một ngôn ngữ có thể được phân loại là nhịp điệu theo nhấn (stress-timed) hoặc nhịp điệu theo âm tiết (syllable-timed), trong đó ở các ngôn ngữ theo nhịp điệu nhấn, thời lượng của các âm tiết nhấn thường chi phối tổng thời gian để phát hoàn chỉnh một câu, còn trong các ngôn ngữ theo nhịp điệu âm tiết, mỗi âm tiết nhận một lượng thời gian gần như bằng nhau trong quá trình phát âm. Ngữ điệu mô tả sự biến thiên cao độ theo chuỗi thời gian của lời nói; người học các ngôn ngữ thanh điệu như tiếng Việt hay tiếng Trung thường gặp khó khăn trong việc nắm bắt và tái hiện chính xác các đường nét cao độ (pitch contour), đặc biệt khi tiếng mẹ đẻ của họ không mang tính thanh điệu, sự khác biệt này khiến cùng một chuỗi đoạn âm có thể mang nghĩa hoàn toàn khác nhau tùy vào sự thay đổi trong cao độ [2]. Hình 1 minh họa sự phân loại của các loại lỗi hiện nay, bao gồm lỗi âm vị và lỗi siêu phân đoạn

Mục tiêu đề ra của các hệ thống MDD hiện nay là có thể phát hiện được các phân đoạn được phát âm sai và cung cấp chẩn đoán cho các khâu tiếp theo hoặc trực tiếp phản hồi cho người học, hệ thống này được kì vọng có thể đánh giá năng lực phát âm ở cả cấp độ siêu phân đoạn (trọng âm, ngữ điệu và nhịp điệu) và cấp độ phân đoạn (âm vị và từ); tuy nhiên, do tính chất đa dạng trong quy luật của cấp độ siêu phân đoạn trong từng ngôn ngữ bắt nguồn khác nhau cũng như những khó khăn trong việc đạt được sự đồng thuận cao, nghiên cứu hiện nay chủ yếu tập trung vào đánh giá cấp độ phân đoạn do tính khả thi và đơn giản trong việc truyền tải thông tin cho người học, đồng thời vẫn còn nhiều thiếu sót cần được cải thiện triệt để trong nhánh nghiên cứu này.

Đề tài này nhằm cung cấp một cái nhìn tổng quan về các kiến trúc phát hiện và chẩn đoán lỗi phát âm (MDD) ở mức âm vị đã và đang được phát triển trong thời gian gần đây và phân tích những điểm mạnh và hạn chế của từng hướng tiếp cận. Đồng thời áp dụng và phát triển một mô hình MDD lấy ý tưởng từ các phương pháp trên và tinh chỉnh mô hình đó cho dữ liệu tiếng Việt, nêu lên những khó khăn trong quá trình phát triển một hệ thống MDD. Dựa trên các kết quả thực nghiệm thu được, nghiên cứu này cũng đóng góp cho lĩnh vực MDD theo ba khía cạnh chính như sau:

- Cung cấp bằng chứng thực nghiệm cho thấy trong các hệ thống MDD theo hướng dựa trên chuỗi chuẩn (prompt-based), việc tăng cường cho kiến trúc của tác vụ nhận dạng âm vị có thể cải thiện đáng kể hiệu quả phát hiện lỗi phát âm khi hai tác vụ này được huấn luyện đồng thời.
- Xây dựng một mô hình MDD hoàn toàn dựa trên các phương pháp học sâu end-to-end, với mức độ phụ thuộc tối thiểu vào kiến thức miền trong xử lý tiếng nói; mô hình này có thể được sử dụng như một chuẩn tham chiếu đảm bảo chất lượng (quality assurance benchmark) cho các nghiên cứu trong tương lai trong lĩnh vực MDD.
- Tinh chỉnh mô hình nói trên cho người học tiếng Anh như ngôn ngữ thứ hai (L2), trong đó tiếng Việt là ngôn ngữ mẹ đẻ, nhằm phản hồi tốt hơn với các đặc trưng và kiểu lỗi phát âm đặc thù của nhóm người học này.


1.1 Các phương pháp đã được phát triển hiện nay trong lĩnh vực

Trước khi các mô hình học sâu trích xuất thông tin được phát triển, đã có các attempt khác nhau nhằm tạo ra các hệ thống nhận diện lỗi phát âm sử dụng những phương pháp căn bản. Các phương pháp trong những giai đoạn phát triển hệ thống MDD đầu tiên chủ yếu dựa trên ba nhóm phương pháp chính: Phân loại dựa trên âm học (acoustic phonetics), Mạng nhận diện mở rộng (Extended Recognition Networks – ERN), các dạng chấm điểm mức độ phát âm chuẩn (Goodness of Pronunciation – GOP). Các phương pháp phân loại sử dụng những đặc trưng âm học như phổ năng lượng MFCC và thông tin ngữ điệu và áp dụng cho phương pháp học máy cổ điển như Phân tích tuyến tính (LDA) hay sử dụng Cây quyết định (Decision trees) nhằm phân biệt giữa các trường hợp phát âm đúng và phát âm sai trong những cặp âm mục tiêu. Tuy nhiên, phương pháp này đòi hỏi nhãn lỗi ở mức âm vị và khó mở rộng cho nhiều ngôn ngữ hay nhiều loại lỗi. ERN mở rộng từ điển của hệ thống ASR với các biến thể lỗi do chuyên gia thiết kế để nhận dạng những cách phát âm sai trong quá trình giải mã, cung cấp khả năng chẩn đoán chi tiết nhưng phụ thuộc mạnh vào luật và ngôn ngữ, đồng thời tốn kém khi xây dựng. Trong khi đó, GOP tính toán các điểm số giống hậu nghiệm từ mô hình HMM–GMM hoặc DNN–HMM để đo mức độ “giống người bản ngữ” của từng âm vị sau khi căn chỉnh cưỡng bức (force alignment), mang lại khả năng tính toán hiệu quả và tương quan tốt với đánh giá thủ công; tuy nhiên GOP vẫn chỉ hoạt động như thước đo độ tin cậy ở mức âm vị, thiếu ngữ cảnh, thiếu mô hình hoá ngữ điệu và không thể xác định rõ ràng kiểu lỗi (thêm, bớt, thay thế). Những hạn chế về khả năng mở rộng, phụ thuộc ngôn ngữ và biểu diễn ngữ cảnh, cũng như độ tốn kém trong khâu thiết kế nhãn là lý do thúc đẩy sự chuyển dịch sang các mô hình end-to-end (E2E) linh hoạt hơn, sử dụng các mô hình học sâu để giảm lược yêu cầu căn chỉnh thủ công và tự động học các quy luật lỗi phát âm.

Các phương pháp thiết kế mô hình MDD theo hướng E2E hiện nay thường rơi vào nhưng không giới hạn trong những nhánh phương pháp sau:

1.1.1 Phương pháp dựa trên chấm điểm

Một trong những phương pháp phổ biến trong phát hiện lỗi phát âm ở mức âm vị là đo chỉ số tương đương giữa âm vị mà người học phát âm so với cách phát âm chuẩn của người bản xứ. Phương pháp này thường phụ thuộc vào một mô hình ASR được huấn luyện chuyên sâu trong nhận dạng âm tiết để trích xuất được độ tin cậy (confidence



Hình 2: Kiến trúc mô hình chấm điểm CaGOP

score) và qua đó tính toán số điểm của từng âm [5]. Trong phương pháp chấm điểm, đoạn văn bản cần xét sẽ được tách ra ở mức âm vị theo 1 trong 2 cách: IPA, sử dụng những ký hiệu âm trong bảng âm global, hoặc ARPABET, chuyên dùng trong phân tích ngôn ngữ Anh, trong bài báo cáo này sẽ tận dụng chủ yếu phương pháp tách thứ 2. Cùng với đó, đoạn âm thanh sẽ được phân tách thành các đoạn khung hình có cùng độ dài, thông thường là 10-20 mili giây. Sau đó thực hiện căn chỉnh cường độ bằng thuật toán hoặc căn chỉnh mềm bằng các phương pháp học máy/học sâu với đoạn âm thanh cần xét và chấm điểm độ tương đương giữa đoạn âm thanh được căn chỉnh với âm tiết nó được căn chỉnh vào. Cách chấm điểm cho các âm vị được phát âm sẽ dựa trên xác suất của các khung hình đó liệu có tương đương với cách phát âm của âm tiết đang được xét không. Một cách chấm điểm kinh điển theo cơ chế này được mô tả trong nghiên cứu của S.M Witt, S.J. Young năm 1998: Phone-level pronunciation scoring and assessment for interactive language learning, là Goodness-of-pronunciation (GOP). Ví dụ, khi chấm phát âm cho từ “cat”, từ này sẽ được phân tách thành một chuỗi âm vị gốc như “K AE T”, sau đó âm thanh tương ứng do người học phát âm sẽ được căn chỉnh với chuỗi âm vị trên, từ đó có thể chấm điểm phát âm của từng âm vị.

Giả sử $O^{(p)}$ là đoạn các khung hình âm thanh được căn chỉnh với âm tiết p trong đoạn các âm tiết cần chấm điểm, GOP của một âm vị p được định nghĩa là log của xác suất hậu nghiệm (log posterior probability) $p(p | O^{(p)})$ được chuẩn hóa (normalized) theo độ dài của đoạn $O^{(p)}$, ký hiệu là $NF(p)$. Cụ thể:

$$GOP(p) = \frac{1}{NF(p)} \cdot \log p(p | O^{(p)}) = \frac{1}{NF(p)} \cdot \log \frac{p(O^{(p)} | p) \cdot p(p)}{\sum_{q \in Q} p(O^{(p)} | q) \cdot p(q)} \quad (1)$$

Với Q là tập tất cả các mẫu âm vị chuẩn đã được xác định [4].

Độ đúng/sai của đoạn âm thanh được xác định dựa trên ngưỡng, ví dụ số điểm GOP trả ra là 0.7, với ngưỡng 0.5, đoạn âm thanh này sẽ được chấm là Đúng.

Nhiều nghiên cứu hiện nay đã mở rộng phương pháp tính điểm này bằng những cách như đơn giản hóa quá trình căn chỉnh bằng căn chỉnh mềm sử dụng học sâu. Một nghiên cứu mới trong phương pháp tính điểm mang tên Context-aware GOP scoring (CaGOP) vào năm 2020 đã chỉ ra rằng, cách tính điểm GOP truyền thống đã bỏ qua một số chi tiết về ngữ cảnh bên trong và giữa các đoạn âm vị [6]. Trong GOP cổ điển của S.M. Witt được miêu tả ở trên, cơ chế căn chỉnh cường độ đã chia toàn bộ chuỗi âm thanh thành các đoạn âm vị tương ứng với các âm vị chuẩn. Tuy nhiên, trong lý thuyết của quy trình tạo ra lời nói, dây thanh quản của con người sẽ chuyển giao dần dần giữa các âm vị khác nhau trong một từ, cũng như chứa các khoảng trống giữa các từ, vì vậy, khi căn chỉnh cường độ sẽ kéo theo những vùng chuyển tiếp này vào quá trình tính điểm, dẫn tới độ nhiễu vốn không liên quan đến âm vị mục tiêu. Để khắc phục cho điểm yếu này, dựa trên ý tưởng về entropy - chỉ số độ bất định của các biến ngẫu

nhiên, nhóm tác giả đã bổ sung một trọng số entropy nhằm giảm độ ảnh hưởng của các khung âm thanh chuyển giao trong quá trình tính điểm GOP. Cụ thể hơn, trong mỗi khung hình, entropy thấp biểu thị mô hình dự đoán âm vị có độ tự tin cao, trái lại, entropy với độ dao động cao cho ta thấy mô hình dự đoán đang gặp khó khăn trong việc nhận biết âm vị tương ứng, đồng nghĩa với việc khung hình âm thanh đang xét có khả năng cao là khung chuyển tiếp. Công thức của GOP được biểu diễn lại dưới dạng:

$$GOP(p) = \frac{1}{NF(p)} \sum_{t=1}^{NF(p)} \log p(p|o_t) = \frac{1}{NF(p)} \sum_{t=1}^{NF(p)} \log \left(\frac{p(o_t|p)}{\sum_{q \in Q} p(o_t|q)} \right) \quad (2)$$

Trong đó $\log p(p|o_t)$ là log xác suất hậu nghiệm biểu thị mức độ tin cậy của mô hình ASR rằng khung âm thanh o_t tương ứng với âm vị p .

Với entropy E_t của xác suất hậu nghiệm dựa trên khung âm thanh:

$$E_t = - \sum_{q \in Q} p(q|o_t) \cdot \log(p(q|o_t)) \quad (3)$$

Qua đó có thể tính được số điểm bằng cách nhân điểm GOP theo từng khung với nghịch đảo của entropy tương ứng của khung đó:

$$TAScore(p) = \sum_t \frac{\frac{1}{E_t}}{\sum_{t'} \frac{1}{E_{t'}}} \cdot \log p(p|o_t) \quad (4)$$

Bên cạnh đó, phương pháp chấm điểm GOP cổ điển chỉ xét ngữ cảnh bên trong các âm vị nhưng không xét đến ngữ cảnh trong toàn câu, dẫn đến việc xuất hiện nhiều false negative hơn. Trong ngôn ngữ, độ dài của âm vị có thể thay đổi dựa trên cấu trúc của câu và ngữ cảnh, do đó, nếu chấm điểm với GOP cổ điển, những âm vị có số khung âm thanh ít hơn sẽ thường chứa ít khung âm thanh có giá trị hơn, hay nếu dài hơn sẽ có nhiều khung nhiều hơn. Nghiên cứu này đã bổ sung một công đoạn ước chừng độ dài các âm vị đích nhằm tự động điều chỉnh linh hoạt ngưỡng chấm điểm nghiêm ngặt của GOP theo từng ngữ cảnh. Nhóm tác giả đã xây dựng thêm một mô hình dự đoán độ dài của từng âm vị trong một đoạn văn bản đích, trong đó văn bản mục tiêu được chuyển đổi thành chuỗi âm vị, các âm vị được đưa vào lớp nhúng kèm theo véc-tơ tốc độ trung bình của chuỗi và véc-tơ vị trí (positional encoding). Toàn bộ đặc trưng được mã hóa bằng cơ chế windowed self attention với ma trận Gaussian để ưu tiên thông tin cục bộ, sau đó chạy qua một lớp tuyến tính và suy ra độ dài kỳ vọng của từng âm vị phục vụ cho việc điều chỉnh ngưỡng GOP. Mô-đun mã hóa được xây dựng như sau:

$$Attention(q, k, v) = \left(\frac{qk^\top}{\sqrt{d}} + M \right) \cdot v \quad (5)$$

Với M là ma trận Gaussian, với mỗi phần tử:

$$M_{i,j} = \frac{(i-j)^2}{\sigma^2} \quad (6)$$

Trong đó:

- q, k, v lần lượt là vector truy vấn (Query), vector khóa (Key) và vector giá trị (Value) trong cơ chế Attention. q trong công thức (5) khác với q trong công thức (1), (2), (3) được định nghĩa là một trong những âm vị thuộc tập Q
- d là số chiều biểu diễn (feature dimension) của các vector Query/Key

- i, j lần lượt là vị trí của cặp Query và Key đang xét;
- σ là tham số có thể học được.

Sau khi có được thời gian chuẩn dự đoán của từng âm vị đích, ta có thể tiến hành tính toán $\delta(p)$, tức độ khác biệt giữa thời gian chuẩn này với phát âm cần được chấm điểm:

$$\delta(p) = |D_{\text{align}} - D_{\text{pred}}| - T_{a,s} \quad (7)$$

Với:

- D_{align} là thời gian của âm vị được căn chỉnh;
- D_{pred} là thời gian âm vị gốc dự đoán được từ mô hình nói trên;
- $T_{a,s}$ là hệ số cân bằng có thể điều chỉnh, trong bài báo, hằng số $T_{a,s}$ được định nghĩa là tổng giữa trung bình sai số và độ lệch chuẩn sai số nhân 1.5, sai số này được tính trong quá trình huấn luyện mô hình dự đoán độ dài chuẩn.

Sau đó, có thể tính được số điểm GOP với thông tin về ngữ nghĩa được bổ sung như sau:

$$\text{CaGOP}(p) = (1 - \beta \cdot \delta(p)) \text{TAScore}(p) \quad (8)$$

Với β là siêu tham số có thể chỉnh được

Mô hình CaGOP được huấn luyện trên ba tập dữ liệu: LibriSpeech 960 giờ để huấn luyện mô-đun ASR dự đoán âm vị và mô hình dự đoán độ dài; TIMIT để kiểm tra độ chính xác dự đoán độ dài sau khi chuẩn hóa âm vị; và tập CAPT 2.8 giờ của 129 trẻ em không bản ngữ, chia 50% để tinh chỉnh siêu tham số và 50% để đánh giá MDD. Mô hình độ dài sử dụng kiến trúc self-attention gồm 6 tầng với kích thước biểu diễn 256 chiều, được huấn luyện bằng hàm mất mát L1 với bộ tối ưu Noam, và được so sánh với mô hình baseline LSTM. Sau đó, các mô hình được đánh giá bằng chỉ số MAE cho bài toán dự đoán độ dài và accuracy/F1 cho bài toán MDD. Kết quả cho thấy mô hình self-attention giúp giảm 25% MAE so với LSTM, trong khi CaGOP vượt trội hơn GOP hơn 14% MAE trong bài toán MDD, đồng thời xác nhận vai trò rõ rệt của transition factor và duration factor. Kiến trúc mô hình được mô tả ở Hình 2.

Điểm mạnh:

- Cải thiện chỉ số GOP truyền thống thông qua việc bổ sung các nguồn thông tin mới, giúp nâng cao hiệu quả chấm điểm phát âm.

Điểm yếu:

- Vẫn sử dụng phương pháp căn chỉnh bắt buộc dựa trên thuật toán, chưa áp dụng các kiến trúc học sâu linh hoạt hơn.

1.1.2 Mô hình thuần chính tả (Dictation-based model)

Trong những năm gần đây, các kỹ thuật nhận dạng tiếng nói tự động (ASR) tiên tiến đã được phát triển và đạt được những tiến bộ ổn định. Sự phát triển này đã cho ra đời một hướng xây dựng mô hình MDD mới là Dictation-based. Các phương pháp Dictation-based xem MDD như một bài toán nhận diện âm vị, tương tự với nhận dạng tiếng nói tự động do có cùng mục tiêu là giải mã tiếng nói nhưng ở mức độ âm vị. Trong đó, mô hình được huấn luyện thuần

cho tác vụ nhận dạng âm vị, sau đó các lỗi phát âm được phát hiện bằng cách căn chỉnh dãy âm vị là kết quả đầu ra của mô hình này với dãy âm vị gốc (dãy âm vị người học cần phải nói) và đánh dấu các vị trí không khớp. Về mặt thiết kế, mô-đun ASR lỗi không được dẫn dắt bởi dãy âm vị gốc trong quá trình mã hóa/giải mã nên có thể ghi nhận chính xác những gì thực sự được phát âm.

Một nghiên cứu nổi bật trong phương pháp này được đề xuất tại ICASSP2019 nhằm tận dụng phương pháp end-to-end đã kết hợp giữa CNN, RNN và CTC để xây dựng trực tiếp một mô hình nhận dạng dãy âm vị dùng cho MDD. Thay vì căn chỉnh cường độ thông tin âm thanh với dãy âm vị gốc, mô hình CNN-RNN-CTC trực tiếp ánh xạ dãy đặc trưng âm thanh sang dãy âm vị sau đó sử dụng dãy này làm nền tảng để so sánh với dãy âm vị gốc, từ đó tìm ra những điểm bất đối xứng trong phát âm của người nói.

Cấu trúc mô hình được thiết kế đơn giản với năm khối chính như trong Hình 3. Trong đó:

- Lớp đầu vào tiếp nhận dãy đặc trưng âm thanh dưới dạng phổ biên độ (spectrogram) theo các khung và áp dụng Batch Normalization và padding.
- Khối thứ hai bao gồm 4 lớp CNN kết hợp với 2 lớp Max-pooling và chuẩn hóa, đóng vai trò trích xuất các đặc trưng âm học từ tín hiệu đầu vào.
- Khối thứ ba sử dụng kiến trúc Bi-GRU để nắm bắt các đặc trưng phụ thuộc thời gian của chuỗi lời nói. Kiến trúc GRU thay thế LSTM nhằm giảm độ phức tạp và tăng tốc huấn luyện.
- Khối thứ tư là các lớp MLP với hàm softmax ở cuối nhằm phân loại xác suất âm vị tại mỗi khung âm thanh và sử dụng CTC loss để huấn luyện mô hình.

Sau khi huấn luyện, dãy âm vị dự đoán bởi mô hình được căn chỉnh với dãy âm vị gốc bằng thuật toán Needleman–Wunsch. Từ kết quả căn chỉnh này, các lỗi substitution, insertion và deletion được trích xuất. Những lỗi này được sử dụng trực tiếp cho hai nhiệm vụ: (1) Mispronunciation Detection – xác định âm vị có phát âm sai hay không; (2) Mispronunciation Diagnosis – xác định cụ thể loại lỗi phát âm.


Để huấn luyện và đánh giá mô hình, nhóm tác giả sử dụng bộ dữ liệu TIMIT và tập CU-CHLOE (Chinese University Chinese Learners of English), bao gồm lời nói tiếng Anh của 100 người nói tiếng Quảng Đông và 110 người nói tiếng Trung phổ thông. So với các phương pháp dựa trên căn chỉnh cường độ trước đây, mô hình CNN-RNN-CTC đạt F1-score 74.62% trên cùng tập kiểm tra với các nghiên cứu trước đó, đồng thời cạnh tranh trực tiếp với các phương pháp này mà không sử dụng các kỹ thuật trích xuất chuyên sâu vốn thường đòi hỏi thiết kế cẩn thận dựa trên kiến thức miền (domain knowledge).

Ưu điểm:

- Loại bỏ công đoạn căn chỉnh cường độ và yêu cầu tối thiểu kiến thức miền.
- Trực tiếp khai thác mô hình nhận dạng âm vị được xây dựng dựa trên kiến trúc của các hệ thống ASR hiện có.
- Mô hình có cấu trúc đơn giản, dễ mở rộng và có tiềm năng tăng cường hiệu năng thông qua việc tích hợp các kỹ thuật trích xuất và xử lý tín hiệu âm thanh dựa trên kiến thức miền.

Nhược điểm:

- Đầu ra của mô hình chỉ dự đoán các âm vị rời rạc, không cung cấp điểm số liên tục ở mức âm vị như các phương pháp dựa trên GOP, do đó hạn chế khả năng hỗ trợ phản hồi định lượng chi tiết cho người học.
- Tồn tại sự mất cân bằng giữa Precision và Recall.



Hình 3: Kiến trúc mô hình CNN–RNN–CTC

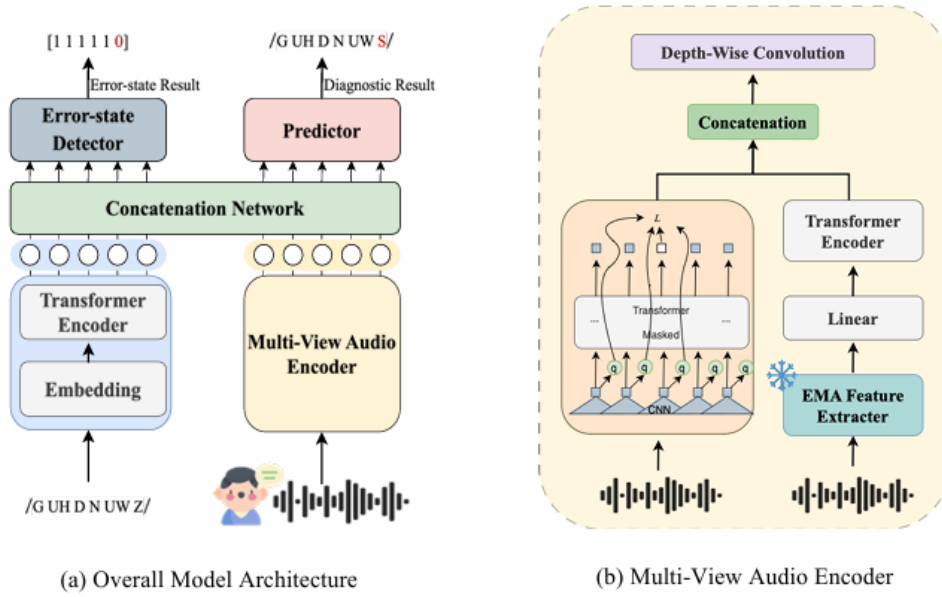
1.1.3 Mô hình thuần gợi ý (Prompt-based model)

Một phương pháp mới xuất hiện trong năm 2023-2024 là loại mô hình prompt-based nhằm tối việc huấn luyện mô hình đa tác vụ. Bên cạnh công việc nhận diện âm vị, các mô hình này cũng bổ sung một nhánh phát hiện lỗi phát âm trực tiếp. Thay vì chỉ dựa trên dãy âm vị dự đoán được để căn chỉnh và phát hiện lỗi, mô hình sử dụng cơ chế attention nhằm thực hiện căn chỉnh mềm giữa dãy âm vị gốc và dãy đặc trưng trích xuất được từ đoạn âm thanh, từ đó phát hiện và chẩn đoán lỗi thông qua tương tác giữa hai biến đầu vào này.

Mô hình điển hình trong hướng tiếp cận này là Prompt-guided Mispronunciation Detection and Diagnosis (PG-MDD), được đề xuất vào năm 2024 với nhiều phương pháp xử lý âm thanh mới. Mô hình được cấu tạo bởi năm thành phần chính, bao gồm:

- **Bộ mã hóa âm vị gốc:** Mô hình nhận vào dãy âm vị gốc và tiến hành mã hóa thông qua một lớp Embedding và một lớp Transformer.
- **Bộ mã hóa âm thanh đa góc nhìn:** Một ưu điểm nổi bật của mô hình là thay vì xây dựng một bộ mã hóa âm thanh riêng biệt, các tác giả sử dụng trực tiếp mô-đun mã hóa âm thanh wav2vec 2.0 đã được huấn luyện sẵn cho tác vụ nhận dạng âm vị. Bên cạnh đó, mô hình còn tích hợp một mô-đun trích xuất đặc trưng cấu âm (Electromagnetic Articulography – EMA) nhằm bổ sung thông tin về cơ chế hình thành âm thanh thông qua chuyển động của thanh quản và khoang miệng. Các đặc trưng EMA được xử lý bởi một lớp MLP và bộ mã hóa Transformer trước khi được ghép nối với các đặc trưng âm thanh trích xuất từ mô-đun wav2vec 2.0. Biểu diễn ghép nối sau đó được đưa qua một lớp tích chập theo chiều kênh (Depth-wise Convolution) để tinh chỉnh, tạo ra chuỗi vector đặc trưng âm thanh đa góc nhìn.
- **Bộ ghép nối:** Đầu ra từ hai bộ mã hóa âm vị gốc và mã hóa âm thanh được đưa qua một khối gồm hai lớp Transformer nhằm mô hình hóa tương tác giữa hai nguồn thông tin và sinh ra các biểu diễn học tương ứng.
- **Bộ phát hiện lỗi âm vị:** Biểu diễn từ bộ mã hóa âm vị gốc sau khi tương tác được sử dụng để tính hàm mất mát với dãy nhãn phát hiện lỗi cần học, thông qua hàm negative log-likelihood (NLLLoss).
- **Bộ nhận diện dãy âm vị:** Biểu diễn từ bộ mã hóa âm thanh sau khi tương tác được sử dụng để tính hàm mất mát với dãy âm vị thực tế mà người nói đã phát âm, sử dụng phương pháp Connectionist Temporal Classification (CTC).

Trong giai đoạn huấn luyện, mô hình PG-MDD trước hết tối ưu hóa đồng thời hai quá trình phát hiện lỗi phát âm và chẩn đoán lỗi, sau đó dẫn dắt hiệu quả quá trình chẩn đoán trong giai đoạn suy luận (inference) thông qua các



Hình 4: Kiến trúc mô hình PG-MDD

ngưỡng nhận diện lỗi, phụ thuộc theo từng âm vị. Nhờ ngưỡng riêng cho từng âm vị này, hệ thống có thể chấm lỏng tay với những âm vốn dễ bị false positive và siết chặt với những âm hay bị bỏ sót, từ đó cân bằng hơn giữa việc không bỏ sót lỗi (recall) và tỉ lệ phát âm đúng (precision). Trong mô tả thí nghiệm, mô hình được huấn luyện và kiểm tra sử dụng tập dữ liệu L2-ARCTIC, chứa các đoạn ghi âm nói tiếng Anh của người không bản xứ, với bộ mã hóa âm thanh wav2vec2 được tinh chỉnh cho tác vụ nhận diện âm vị bằng tập dữ liệu TIMIT, bao gồm các đoạn lời nói tiếng Anh của người bản xứ. Sau quá trình tinh chỉnh ngưỡng đầu ra, mô hình đạt được số điểm F1-score là 60.1% với Precision 60.15% và Recall đạt 60.06%, cao nhất trên tập dữ liệu kiểm tra L2-ARCTIC tính tới thời điểm năm 2024.

Ưu điểm:

- Mô hình đạt được giá trị F1-score cao, đồng thời duy trì được sự cân bằng hợp lý giữa hai chỉ số Precision và Recall.

Nhược điểm:

- Mô hình yêu cầu phải xây dựng và huấn luyện trước một mô hình Electromagnetic Articulography (EMA), dẫn đến độ phức tạp cao trong quá trình phát triển hệ thống. Ngoài ra, việc tích hợp mô-đun EMA còn làm tăng thời gian suy luận. Trong kiến trúc tổng thể, các mô-đun wav2vec 2.0 và EMA chiếm phần lớn số lượng tham số của mô hình.
- Quá trình tinh chỉnh ngưỡng quyết định cho từng âm vị trong giai đoạn suy luận vẫn được thực hiện thủ công, gây tốn thời gian trong quá trình phát triển và thường đòi hỏi sự giám sát cũng như điều chỉnh thường xuyên khi phân bố lỗi phát âm của dữ liệu đầu vào thay đổi.

1.1.4 Nhận xét chung

Khó khăn chung của các mô hình Mispronunciation Detection and Diagnosis (MDD) nằm ở sự thiếu hụt dữ liệu sạch phản ánh lời nói của người học tiếng Anh như ngôn ngữ thứ hai (L2), đồng thời các dạng lỗi phát âm có mức độ đa dạng cao và phụ thuộc mạnh vào ngôn ngữ gốc (L1) của người nói. Quá trình xây dựng và gán nhãn dữ liệu cho các hệ thống này đòi hỏi sự tham gia của các chuyên gia có trình độ chuyên môn cao, trong khi việc đảm bảo tính nhất quán và độ chính xác của nhãn lại tiêu tốn nhiều thời gian và nguồn lực.

Bên cạnh đó, phần lớn các mô hình MDD được đề xuất nhằm hướng tới khả năng triển khai thực tế, do đó các tập kiểm tra thường được thiết kế để bao phủ nhiều nhóm người nói với nền tảng ngôn ngữ khác nhau. Tuy nhiên, điều này dẫn đến những hạn chế trong việc so sánh và đánh giá mô hình trong các ngữ cảnh cụ thể. Một số nghiên cứu sử dụng các tập kiểm tra khác nhau giữa các mô hình, ví dụ như CaGOP đã sử dụng tập dữ liệu kiểm tra riêng biệt so với ba phương pháp còn lại, gây khó khăn cho việc đánh giá mô hình một cách công bằng, đặc biệt trong bối cảnh giảng dạy tiếng Anh L2 cho người học có ngôn ngữ gốc là tiếng Việt.

Trên cơ sở đó, đồ án này tập trung vào việc phát triển và tối ưu hóa một mô hình MDD chuyên biệt cho đối tượng người học tiếng Anh có tiếng mẹ đẻ là tiếng Việt, nhằm thu hẹp khoảng cách giữa nghiên cứu học thuật và yêu cầu ứng dụng thực tiễn.

CHƯƠNG 2. MỤC TIÊU, ĐỊNH HƯỚNG VÀ GIẢI PHÁP

2.1 Mục tiêu hệ thống

Mục tiêu của hệ thống là triển khai một giải pháp phát hiện và sửa lỗi phát âm trong thời gian thực, có khả năng nhận diện các lỗi phát âm và cung cấp phản hồi kịp thời cho người học. Hệ thống được tinh chỉnh chuyên biệt cho đối tượng người học tiếng Anh như ngôn ngữ thứ hai (L2) có ngôn ngữ gốc là tiếng Việt.

Hệ thống được thiết kế theo kiến trúc tích hợp, tập trung vào việc thử nghiệm, giám sát và thu thập kết quả hoạt động của mô hình, nhằm đánh giá và chứng minh tính khả thi của mô hình trong quá trình triển khai thực tế.

Cụ thể, mô hình hướng tới các mục tiêu sau:

- **Đầu vào:** Đoạn ghi âm lời nói của người học và đoạn văn bản đích cần được phát âm.
- **Đầu ra:** Chuỗi phát hiện lỗi phát âm và chuỗi âm vị tương ứng với đoạn ghi âm đầu vào.
- **Yêu cầu chức năng:** Đảm bảo mô hình có khả năng nhận diện lỗi phát âm và phản hồi chính xác ngay cả trong điều kiện môi trường có nhiều nhiễu nền, không phụ thuộc chặt chẽ vào chất lượng tín hiệu âm thanh đầu vào.

2.2 Định hướng giải pháp tổng thể

- Giải pháp được đề xuất theo hướng end-to-end, dựa trên phương pháp thuần gợi ý (Prompt-based), trong đó hệ thống xử lý trực tiếp tín hiệu âm thanh đầu vào và sinh ra kết quả phát hiện lỗi phát âm mà không cần các bước trung gian phức tạp. Mô hình sử dụng bộ mã hóa âm thanh tiên tiến wav2vec 2.0, kết hợp với các kiến trúc học sâu cơ bản nhằm tận dụng hiệu quả các biểu diễn ngữ âm học được huấn luyện sẵn.
- Chuyển đổi văn bản đích thành chuỗi âm vị theo chuẩn ARPABET. Chuỗi này đóng vai trò làm tham chiếu trong quá trình huấn luyện và suy luận. Trên cơ sở đó, mô hình sẽ được yêu cầu có khả năng nhận diện chính xác các âm vị từ tín hiệu âm thanh đầu vào.
- Xây dựng và điều chỉnh chuyên biệt một bộ dữ liệu cho bài toán nhằm phản ánh đúng đặc trưng phát âm của người học tiếng Anh L2 có ngôn ngữ gốc là tiếng Việt, từ đó nâng cao hiệu quả và tính khả thi khi triển khai trong thực tế.
- Xây dựng thêm giao diện web nhằm kiểm thử mô hình trong điều kiện thực tế, đồng thời thu thập dữ liệu suy luận (inference).

2.3 Kỳ vọng hệ thống

Độ chính xác: Hệ thống được kỳ vọng đạt điểm số F1 tương đương hoặc cao hơn mức 0.49 của phương pháp CaGOP, và tiệm cận hoặc vượt mức 0.60 của phương pháp PG-MDD — hiện được xem là trạng thái tốt nhất (state of the art) trên tập kiểm tra L2-ARCTIC.

Thời gian phản hồi: Hệ thống cần đảm bảo thời gian phản hồi nhanh, đáp ứng yêu cầu triển khai thực tế của các ứng dụng phân tích và phản hồi lỗi phát âm trong thời gian gần thực.

Khả năng mở rộng: Mô hình có khả năng tích hợp thêm các mô-đun nhận diện lỗi khác, chẳng hạn như lỗi nhấn trọng âm, hoặc được tăng cường bằng các hướng tiếp cận bổ sung như khai thác thông tin cấu âm thông qua bộ trích xuất cấu âm (Articulatory Extractor) tương tự PG-MDD, sử dụng thông tin độ dài âm vị như trong CaGOP, hoặc mở rộng dữ liệu nhằm cải thiện độ chính xác sau các giai đoạn thử nghiệm.

Giao diện suy luận: Hệ thống giám sát cần hỗ trợ thu thập dữ liệu suy luận để phục vụ cho việc phân tích hiệu năng và tinh chỉnh mô hình trong các bước phát triển tiếp theo.

2.4 Các kiến trúc và hệ thống được sử dụng

Để xây dựng mô hình, dựa trên kinh nghiệm rút ra từ các kiến trúc mô hình MDD đã được xây dựng từ trước cần phải sử dụng một số phương pháp như CNN, B-LSTM, MLP, Attention, Transformer. Bên cạnh đó cũng khai thác framework encoder Wav2vec 2.0 và huấn luyện mô hình sử dụng Pytorch và Huggingface wrapper.

2.4.1 Mạng nơ-ron nhiều lớp (Multilayer Perceptron – MLP)

Là cấu trúc mạng học sâu đơn giản nhất, thuộc kiến trúc mạng nơ-ron truyền thẳng đa lớp, được David Rumelhart, Geoffrey Hinton và Ronald Williams hoàn thiện vào năm 1986 sau khi phổ biến kỹ thuật Lan truyền ngược (Back-propagation), nhằm mục đích giải quyết các bài toán phi tuyến tính phức tạp mà mạng Perceptron đơn lớp trước không thể xử lý được. Một MLP tiêu chuẩn là một đồ thị có hướng không chu trình, gồm các nơ-ron xếp chồng lên nhau, phân làm 3 loại lớp chính:

- Lớp đầu vào (Input layer): Nhận một vector đặc trưng đầu vào. Lớp này không thực hiện tính toán, chỉ thực hiện truyền dẫn.
- Các lớp ẩn (Hidden layers): Nơi thực hiện quá trình biểu diễn dữ liệu. Một mạng có thể có 1 hoặc hàng trăm lớp ẩn. Các nơ-ron ở lớp này được kết nối đầy đủ (Fully connected) với các lớp ở trước.
- Lớp đầu ra (Output layer): Biến đổi biểu diễn ẩn thành kết quả dự đoán.

MLP sẽ trải qua 2 quá trình tính toán: Lan truyền xuôi (Forward Propagation) và Lan truyền ngược (Backward Propagation). Cụ thể:

a. Lan truyền xuôi

Giả sử mạng chỉ có 1 lớp ẩn chứa h nơ-ron. Ta kí hiệu $X \in R^{n \times d}$ là dữ liệu trong lớp đầu vào, $H \in R^{n \times h}$ là đầu ra của lớp ẩn, và trọng số của lớp ẩn là $W^{(1)} \in R^{n \times h}$ và bias $b^{(1)} \in R^{1 \times h}$, cùng với trọng số của lớp đầu ra $W^{(2)} \in R^{h \times q}$ và bias tương ứng $b^{(2)} \in R^{1 \times q}$. Các biến bias đóng vai trò tịnh tiến ngưỡng kích hoạt. Quá trình này sẽ sử dụng 2 phép toán cơ bản tại mỗi nơ-ron: Biến đổi tuyến tính và biến đổi phi tuyến:

Biến đổi tuyến tính

Đầu ra tại lớp ẩn có dạng:

$$H = XW^{(1)} + b^{(1)} \quad (9)$$

Tại đây, mỗi nơ-ron tổng hợp thông tin từ các nơ-ron lớp trước, trọng số hóa mức độ quan trọng của từng đầu vào.

Biến đổi phi tuyến tính

Nếu mạng chỉ có nhiều phép đổi tuyến tính,

$$\begin{aligned} O &= HW^{(2)} + b^{(2)} \\ &= (XW^{(1)} + b^{(1)})W^{(2)} + b^{(2)} \\ &= XW^{(1)}W^{(2)} + b^{(1)}W^{(2)} + b^{(2)} \end{aligned} \quad (10)$$

Đặt:

- $W = W^{(1)}W^{(2)}$

• $b = b^{(1)}W^{(2)} + b^{(2)}$

Ta có thể rút gọn được phương trình tổng quát:

$$O = XW + b \tag{11}$$

Có thể thấy toàn bộ mạng nơ-ron, cho dù sâu đến bao lâu cũng chỉ tương đương với một công thức biến đổi tuyến tính và không thể giải quyết các bài toán phức tạp. Chính vì vậy, ta cần một hàm kích hoạt phi tuyến tính σ cho lớp ẩn:

$$\begin{aligned} H &= \sigma(XW^{(1)} + b^{(1)}) \\ O &= HW^{(2)} + b^{(2)} \end{aligned} \tag{12}$$

Một số hàm phi tuyến tính thường gặp:

Hàm kích hoạt	Công thức	Đặc điểm	Nhược điểm
Sigmoid	$\sigma(z) = \frac{1}{1+e^{-z}}$	Chuyển giá trị về $[0, 1]$. Thường dùng mô phỏng xác suất hoặc ở lớp ra nhị phân.	Vanishing Gradient: Đạo hàm tiến về 0 khi giá trị đầu vào rất lớn hoặc rất nhỏ.
Tanh	$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	Chuyển giá trị về $[-1, 1]$. Đồ thị đối xứng qua 0 giúp hội tụ nhanh hơn Sigmoid.	Vẫn bị Vanishing Gradient.
ReLU	$\text{ReLU}(z) = \max(0, z)$	Phổ biến nhất hiện nay. Giảm thiểu hiện tượng Vanishing Gradient ở miền dương ($z > 0$).	Nơ-ron sẽ không thể tính toán nếu như rơi vào miền âm, tại đó đạo hàm =0.
Leaky ReLU	$\text{Leaky ReLU}(z) = \max(\alpha z, z), \alpha \ll 1$	Biến thể của ReLU. Cho phép độ dốc nhỏ để các nơ-ron ở miền âm không bị “chết”.	Cần tinh chỉnh tham số α .
GELU	$\text{GELU}(x) \approx 0.5x \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} (x + 0.044715x^3) \right) \right)$	Biến đổi trơn, kết hợp ưu điểm của ReLU và tính ngẫu nhiên nhẹ giúp hội tụ tốt hơn.	Tính toán phức tạp hơn ReLU, cần nhiều tài nguyên hơn.

Bảng 1: Các hàm kích hoạt phổ biến trong mạng nơ-ron và đặc điểm của chúng

Giả sử tại lớp đầu ra sẽ sử dụng hàm kích hoạt đồng nhất: $\sigma(x) = x$ cho bài toán hồi quy. Giá trị của lớp đầu ra sẽ có dạng:

$$\hat{y} = O = HW^{(2)} + b^{(2)} \quad (13)$$

Sau đó, hàm mất mát $\mathcal{L}(\hat{y}, y)$ sẽ được tính toán. Hàm mất mát là sự chênh lệch giữa giá trị dự đoán và giá trị thực tế. Giá trị hàm mất mát càng cao thì mô hình dự đoán càng lệch, và ngược lại.

b. Lan truyền ngược

Cơ chế học của MLP là quá trình tối ưu hóa trọng số để giảm thiểu hàm mất mát. Quá trình này dựa vào Nguyên lý Chuỗi (Chain Rule).

Quá trình thực hiện như sau:

Tính hàm mất mát

Ví dụ trong bài toán hồi quy, sử dụng hàm mất mát MSE:

$$L = \frac{1}{2}(\hat{y}, y)^2 = \frac{1}{2}(O - y)^2 \quad (14)$$

Tính Gradient

Ta cần cập nhật các trọng số cho $\mathbf{W}^{(2)}$, $\mathbf{W}^{(1)}$, $\mathbf{b}^{(2)}$, $\mathbf{b}^{(1)}$ bằng cách tính đạo hàm của hàm mất mát theo các trọng số đó, sử dụng quy tắc chuỗi (Chain rule). Gradient sẽ chạy từ lớp đầu ra cho đến lớp đầu tiên.

Tại tầng O :

$$\mathbf{O} : \delta_O = \frac{\partial L}{\partial \mathbf{O}} = \frac{2}{n}(\mathbf{O} - \mathbf{y}) \quad (15)$$

Với $\mathbf{W}^{(2)}$:

$$\frac{\partial L}{\partial \mathbf{W}^{(2)}} = \frac{\partial L}{\partial \mathbf{O}} \cdot \frac{\partial \mathbf{O}}{\partial \mathbf{W}^{(2)}} = \mathbf{H}^T \delta_O \quad (16)$$

Với $\mathbf{b}^{(2)}$:

$$\frac{\partial L}{\partial \mathbf{b}^{(2)}} = \frac{\partial L}{\partial \mathbf{O}} \cdot \frac{\partial \mathbf{O}}{\partial \mathbf{b}^{(2)}} = \sum \delta_O \quad (17)$$

Tại tầng H :

$$\frac{\partial L}{\partial \mathbf{H}} = \frac{\partial L}{\partial \mathbf{O}} \cdot \frac{\partial \mathbf{O}}{\partial \mathbf{H}} = \delta_O (\mathbf{W}^{(2)})^T \quad (18)$$

Đặt $\mathbf{Z}^{(1)} = \mathbf{XW}^{(1)} + \mathbf{b}^{(1)}$, suy ra $\mathbf{H} = \sigma(\mathbf{Z}^{(1)})$

$$\frac{\partial L}{\partial \mathbf{W}^{(1)}} = \frac{\partial L}{\partial \mathbf{H}} \cdot \underbrace{\frac{\partial \mathbf{H}}{\partial \mathbf{Z}^{(1)}}}_{\delta_H} \cdot \frac{\partial \mathbf{Z}^{(1)}}{\partial \mathbf{W}^{(1)}} \quad (19)$$

$$\delta_H = \frac{\partial L}{\partial \mathbf{H}} \odot \sigma'(\mathbf{Z}^{(1)}) \quad (20)$$

Với $\mathbf{W}^{(1)}$:

$$\frac{\partial L}{\partial \mathbf{W}^{(1)}} = \mathbf{X}^T \cdot \delta_H \quad (21)$$

Với $\mathbf{b}^{(1)}$:

$$\frac{\partial L}{\partial \mathbf{b}^{(1)}} = \frac{\partial L}{\partial \mathbf{H}} \cdot \frac{\partial \mathbf{H}}{\partial \mathbf{Z}^{(1)}} \cdot \frac{\partial \mathbf{Z}^{(1)}}{\partial \mathbf{b}^{(1)}} = \sum \delta_H \quad (22)$$

c. Cập nhật tham số (Gradient Descent)

Công thức cập nhật tổng quát cho trọng số ở lớp l bất kì:

$$W^{[l]} \leftarrow W^{[l]} - \eta \frac{\partial \mathcal{L}}{\partial W^{[l]}} \quad (23)$$

Với η là tốc độ học (learning rate), ảnh hưởng trực tiếp đến tốc độ hội tụ và tính ổn định của quá trình huấn luyện. Vậy ta có:

$$\begin{aligned} \mathbf{W}^{(2)} &\leftarrow \mathbf{W}^{(2)} - \eta \cdot (\mathbf{H}^T \delta_O) \\ \mathbf{b}^{(2)} &\leftarrow \mathbf{b}^{(2)} - \eta \cdot (\sum \delta_O) \\ \mathbf{W}^{(1)} &\leftarrow \mathbf{W}^{(1)} - \eta \cdot (\mathbf{X}^T \delta_H) \\ \mathbf{b}^{(1)} &\leftarrow \mathbf{b}^{(1)} - \eta \cdot (\sum \delta_H) \end{aligned} \quad (24)$$

Trong đồ án này, MLP được sử dụng trong mô-đun dự đoán âm vị, giúp chuyển đổi các vector đặc trưng thành xác suất âm vị, và trong mô-đun dự đoán lỗi quyết định xem đặc trưng đầu vào có phải là lỗi sai hay không.

2.4.2 Mạng nơ-ron tích chập (Convolutional Neural Network – CNN)

Đối với dữ liệu dạng ảnh, dữ liệu thường được biểu diễn dưới dạng một lưới pixel hai hoặc ba chiều. Khi sử dụng mạng nơ-ron truyền thẳng nhiều lớp (MLP), ảnh đầu vào phải được chuyển đổi thành một vector một chiều, dẫn đến việc làm mất thông tin về mối quan hệ cục bộ cũng như vị trí tương đối giữa các điểm ảnh. Bên cạnh đó, đặc trưng kết nối đầy đủ giữa các nơ-ron trong MLP khiến số lượng tham số tăng lên rất nhanh, gây tiêu tốn đáng kể tài nguyên bộ nhớ và chi phí tính toán.

Ví dụ, với một ảnh màu có kích thước $224 \times 224 \times 3$, khi được làm phẳng thành vector một chiều, số chiều đầu vào sẽ là 150528. Nếu vector này được đưa vào một lớp ẩn gồm 1000 nơ-ron, mô hình sẽ cần hơn 150 triệu tham số. Quy mô tham số lớn như vậy không chỉ làm tăng chi phí lưu trữ và huấn luyện mà còn khiến mô hình dễ bị hiện tượng quá khớp (*overfitting*), đặc biệt trong trường hợp tập dữ liệu huấn luyện không đủ lớn.

Ngoài ra, MLP không có cơ chế chia sẻ trọng số cũng như không đảm bảo tính bất biến theo phép tịnh tiến, do đó mô hình gặp nhiều khó khăn trong việc nhận diện cùng một đối tượng khi vị trí của đối tượng đó thay đổi trong ảnh.

CNN là mô hình học sâu mô phỏng vỏ não và thị giác, được Yann LeCun phát triển vào cuối thập niên 1980 và hoàn thiện năm 1998, với sự ra đời của LeNet-5, nhằm mục đích tự động nhận dạng chữ viết tay và ảnh thông qua cơ chế chia sẻ trọng số và bất biến dịch chuyển, với ba tính chất chính:

- **Tính bất biến dịch chuyển:** Trong các lớp đầu tiên, mạng sẽ phản hồi tương tự với cùng một đặc trưng ở bất kỳ vị trí nào trong ảnh.
- **Tính cục bộ:** Các lớp đầu chỉ tập trung vào vùng lân cận nhỏ của ảnh, không xét đến vùng ở xa
- **Khả năng học đặc trưng phân cấp:** Các lớp sâu hơn sẽ nắm bắt được các đặc trưng có phạm vi rộng hơn và mang ngữ nghĩa cao hơn.

CNN hoạt động theo nguyên lý sau:

a. Phép toán tích chập


Thay vì mỗi nơ-ron phải xử lý toàn bộ ảnh đầu vào, mạng nơ-ron tích chập (CNN) sử dụng các bộ lọc có kích thước nhỏ (ví dụ: 3×3) trượt trên ảnh đầu vào để trích xuất đặc trưng cục bộ. Giả sử ảnh đầu vào $\mathbf{I}$ có kích thước $H \times W$

và một bộ lọc $\mathbf{K}$ có kích thước $k \times k$, khi đó giá trị đầu ra tại vị trí (i, j) được tính thông qua tích vô hướng giữa bộ lọc và vùng ảnh tương ứng tại vị trí đó.

Quá trình tích chập này tạo ra một bản đồ đặc trưng (feature map) phản ánh sự hiện diện của các đặc trưng cục bộ trong ảnh, với kích thước thường nhỏ hơn hoặc bằng so với ảnh đầu vào ban đầu, tùy thuộc vào kích thước bộ lọc, bước trượt và cơ chế đệm biên (padding).

$$(I * K)_{ij} = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} I(i+m, j+n) K(m, n) \quad (25)$$


Mỗi bộ lọc trong mạng nơ-ron tích chập có khả năng phát hiện một loại đặc trưng cụ thể của ảnh, chẳng hạn như cạnh ngang, góc, hoặc các đặc trưng liên quan đến màu sắc. Do mỗi kernel được áp dụng trên toàn bộ ảnh đầu vào và sử dụng cùng một tập trọng số cho mọi vị trí không gian, mô hình được bổ sung thêm cơ chế chia sẻ trọng số. Nhờ đó, CNN có tính bất biến theo phép dịch chuyển (translation invariance), cho phép nhận diện cùng một đặc trưng ngay cả khi vị trí của nó trong ảnh thay đổi.



Hình 5: Ví dụ về phép toán tích chập với ma trận 3x3 và bộ lọc 2x2

b. Đệm (Padding)

Để xử lý tình trạng mất pixel ảnh sau khi nhân tích chập, ta có thể thêm pixel xung quanh biên của ảnh đầu vào (thường là giá trị 0), làm tăng kích thước ảnh.




Hình 6: Phép toán tích chập với phép đệm

c. Bước nhảy (Stride)

Bước nhảy (stride) là khoảng dịch chuyển của bộ lọc khi trượt trên ảnh đầu vào hoặc bản đồ đặc trưng (feature map). Tham số này xác định số lượng pixel mà bộ lọc dịch chuyển theo cả chiều ngang và chiều dọc sau mỗi phép tính tích chập, từ đó ảnh hưởng trực tiếp đến mức độ trích xuất đặc trưng cũng như kích thước của đầu ra.

Ví dụ, khi bước nhảy bằng 1, bộ lọc dịch chuyển 1 pixel mỗi lần, giúp quá trình quét diễn ra dày hơn và giữ lại nhiều thông tin chi tiết hơn. Ngược lại, khi bước nhảy bằng 2, bộ lọc dịch chuyển 2 pixel mỗi lần, quá trình quét trở nên thưa hơn, dẫn đến bản đồ đặc trưng đầu ra có kích thước nhỏ hơn.



Hình 7: Phép toán tích chập với bước nhảy là 3 cho chiều cao và 2 cho chiều rộng

d. Kích thước đầu ra

Giả sử ảnh đầu vào có kích thước $n \times n$, bộ lọc có kích thước $f \times f$, với bước nhảy s và độ đệm biên p . Khi đó, kích thước đầu ra của bản đồ đặc trưng là $O \times O$, trong đó O được xác định theo công thức:

$$O = \left\lfloor \frac{n - f + 2p}{s} \right\rfloor + 1 \quad (26)$$


Công thức này đóng vai trò quan trọng trong quá trình thiết kế kiến trúc mạng nơ-ron tích chập, nhằm đảm bảo kích thước các tensor giữa các lớp là tương thích với nhau, từ đó tránh các lỗi phát sinh trong quá trình xây dựng và huấn luyện mô hình.

e. Lớp gộp (Pooling Layer)

Phép gộp là phép toán nhằm mục đích giảm kích thước không gian của Feature Map bằng cách trượt một bộ lọc có kích thước nhỏ trên ảnh và tổng hợp đặc trưng trong vùng mà bộ lọc đi qua, nhằm mục đích giảm chi phí tính toán, giảm overfitting và tăng tính bất biến dịch chuyển ở mức cục bộ mà vẫn giữ được thông tin quan trọng.

Hai phép gộp thường được sử dụng trong mạng nơ-ron tích chập bao gồm:

- **Gộp tối đa (Max Pooling):** Lấy giá trị lớn nhất trong vùng cửa sổ, giúp giữ lại các đặc trưng nổi bật nhất và loại bỏ nhiễu không quan trọng.
- **Gộp trung bình (Average Pooling):** Lấy giá trị trung bình của các phần tử trong vùng cửa sổ, qua đó giữ lại các đặc trưng mang tính tổng quát.




Hình 8: Ví dụ về gộp tối đa với bộ lọc kích thước 2×2

Trong đồ án này, CNN là một thành phần trong framework Wav2Vec 2.0, có tác dụng xử lý tín hiệu âm thanh thô để trích xuất đặc trưng và giảm chiều dữ liệu trước khi đưa vào các lớp Transformer bên trên, giúp mô hình hiểu được cấu trúc cơ bản của âm thanh trong khoảng thời gian rất ngắn.

2.4.3 Mạng bộ nhớ dài-ngắn hạn (Long Short-Term Memory – LSTM)

a. Recurrent Neural Networks (RNN)

Mạng nơ-ron hồi tiếp (Recurrent Neural Network – RNN) là một kiến trúc mạng nơ-ron được thiết kế để xử lý dữ liệu dạng chuỗi, trong đó thứ tự của các phần tử mang thông tin quan trọng và các phần tử có sự phụ thuộc lẫn nhau theo thời gian. Khác với mạng nơ-ron truyền thẳng nhiều lớp (MLP), RNN sử dụng các kết nối hồi tiếp, cho phép mô hình lưu trữ và khai thác thông tin từ các bước thời gian trước thông qua trạng thái ẩn. Mạng lưới RNN có thể được minh họa như trong Hình 9.



Hình 9: Một mạng RNN với trạng thái ẩn

Giả sử tại thời điểm t , ta có một lô dữ liệu đầu vào $\mathbf{X}_t \in \mathbb{R}^{n \times d}$, trong đó mỗi hàng của $\mathbf{X}_t$ tương ứng với một mẫu tại thời điểm t trong tổng số n chuỗi, và d là số chiều của vector đặc trưng đầu vào. Ma trận trọng số kết nối từ đầu vào đến trạng thái ẩn được ký hiệu là $\mathbf{W}_{\text{xh}} \in \mathbb{R}^{d \times h}$, với h là số chiều của trạng thái ẩn.

Gọi $\mathbf{H}_{t-1} \in \mathbb{R}^{n \times h}$ là trạng thái ẩn tại thời điểm trước đó, cùng với ma trận trọng số hồi tiếp $\mathbf{W}_{\text{hh}} \in \mathbb{R}^{h \times h}$. Trong RNN, trạng thái ẩn tại thời điểm t phụ thuộc đồng thời vào đầu vào hiện tại và trạng thái ẩn của bước thời gian trước, được xác định bởi:

$$\mathbf{H}_t = \phi(\mathbf{X}_t \mathbf{W}_{\text{xh}} + \mathbf{H}_{t-1} \mathbf{W}_{\text{hh}} + \mathbf{b}_h) \quad (27)$$

Trong đó $\phi(\cdot)$ là hàm kích hoạt phi tuyến (ví dụ: tanh hoặc ReLU), và $\mathbf{b}_h \in \mathbb{R}^{1 \times h}$ là vector bias của lớp ẩn.


Tại thời điểm t , lớp đầu ra của RNN có dạng tương tự như trong MLP:

$$\mathbf{O}_t = \mathbf{H}_t \mathbf{W}_{\text{hq}} + \mathbf{b}_q \quad (28)$$

Với các tham số của lớp đầu ra bao gồm ma trận trọng số $\mathbf{W}_{\text{hq}} \in \mathbb{R}^{h \times q}$ và vector bias $\mathbf{b}_q \in \mathbb{R}^{1 \times q}$, trong đó q là số chiều của không gian đầu ra.

b. Long Short-Term Memory (LSTM)

Khi xử lý các chuỗi dài, RNN hay gặp tình trạng Suy giảm đạo hàm (Vanishing Gradient): Khi lan truyền ngược qua nhiều bước thời gian, gradient bị nhân liên tiếp với các giá trị nhỏ hơn 1, dẫn đến việc tiến về 0 cực nhanh. Mạng không thể học được sự phụ thuộc giữa các từ cách xa nhau (ví dụ: chủ ngữ ở đầu đoạn văn và động từ ở cuối). Vì vậy, vào năm 1997, Sepp Hochreiter và Jürgen Schmidhuber đã giới thiệu LSTM để giải quyết vấn đề này. LSTM sử dụng trạng thái tế bào (Cell state) $\mathbf{C}_t$, đóng vai trò là bộ nhớ dài hạn, giúp gradient trôi chảy mà không biến mất. Hình 10 minh họa cấu trúc LSTM như sau.



Hình 10: Cấu trúc của một khối LSTM

Giả sử có h nơ-ron ẩn, số lượng lô là n , và số lượng đầu vào là d . Vì vậy nên ma trận đầu vào $\mathbf{X}_t \in \mathbb{R}^{n \times d}$ và trạng thái ẩn của thời điểm trước đó là $\mathbf{H}_{t-1} \in \mathbb{R}^{n \times h}$

Một tế bào LSTM bao gồm ba cổng chính, mỗi cổng sử dụng hàm kích hoạt sigmoid để kiểm soát lượng thông tin được truyền qua theo thời gian.

- **Cổng quên** (*Forget Gate*, $\mathbf{F}_t \in \mathbb{R}^{n \times h}$) có nhiệm vụ quyết định những thông tin nào từ trạng thái bộ nhớ trong quá khứ sẽ được giữ lại hoặc loại bỏ:

$$\mathbf{F}_t = \sigma(\mathbf{X}_t \mathbf{W}_{xf} + \mathbf{H}_{t-1} \mathbf{W}_{hf} + \mathbf{b}_f) \quad (29)$$

- **Cổng đầu vào** (*Input Gate*, $\mathbf{I}_t \in \mathbb{R}^{n \times h}$) xác định tỷ lệ thông tin mới từ đầu vào hiện tại được nạp vào bộ nhớ:

$$\mathbf{I}_t = \sigma(\mathbf{X}_t \mathbf{W}_{xi} + \mathbf{H}_{t-1} \mathbf{W}_{hi} + \mathbf{b}_i) \quad (30)$$

- **Cổng đầu ra** (*Output Gate*, $\mathbf{O}_t \in \mathbb{R}^{n \times h}$) quyết định lượng thông tin từ bộ nhớ được xuất ra để tạo thành trạng thái ẩn tại thời điểm t :

$$\mathbf{O}_t = \sigma(\mathbf{X}_t \mathbf{W}_{xo} + \mathbf{H}_{t-1} \mathbf{W}_{ho} + \mathbf{b}_o) \quad (31)$$

Trong đó, các tham số của mô hình LSTM được định nghĩa như sau:

- Các ma trận trọng số kết nối từ đầu vào đến các cổng: $\mathbf{W}_{xi}, \mathbf{W}_{xf}, \mathbf{W}_{xo} \in \mathbb{R}^{d \times h}$
- Các ma trận trọng số hồi tiếp từ trạng thái ẩn ở thời điểm trước: $\mathbf{W}_{hi}, \mathbf{W}_{hf}, \mathbf{W}_{ho} \in \mathbb{R}^{h \times h}$
- Các vector bias tương ứng với các cổng: $\mathbf{b}_i, \mathbf{b}_f, \mathbf{b}_o \in \mathbb{R}^{1 \times h}$

Ta gọi $\tilde{\mathbf{C}}_t \in \mathbb{R}^{n \times h}$ là trạng thái bộ nhớ ứng viên (*candidate cell state*), có vai trò biểu diễn thông tin mới tại thời điểm t . Cách tính toán $\tilde{\mathbf{C}}_t$ tương tự như các cổng trong LSTM, tuy nhiên sử dụng hàm kích hoạt tanh để giới hạn giá trị trong khoảng $(-1, 1)$. Công thức tính tại thời điểm t được xác định như sau:

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{X}_t \mathbf{W}_{xc} + \mathbf{H}_{t-1} \mathbf{W}_{hc} + \mathbf{b}_c). \quad (32)$$

Trong đó, $\mathbf{W}_{xc} \in \mathbb{R}^{d \times h}$ và $\mathbf{W}_{hc} \in \mathbb{R}^{h \times h}$ là các ma trận trọng số, còn $\mathbf{b}_c \in \mathbb{R}^{1 \times h}$ là vector bias.

Sau khi thông tin đi qua cổng quên và cổng đầu vào, trạng thái tế bào tại thời điểm t được cập nhật theo công thức:

$$\mathbf{C}_t = \mathbf{F}_t \odot \mathbf{C}_{t-1} + \mathbf{I}_t \odot \tilde{\mathbf{C}}_t, \quad (33)$$

trong đó $\odot$ ký hiệu phép nhân từng phần tử (*Hadamard product*).


Cuối cùng, trạng thái ẩn tại thời điểm t được xác định bởi:

$$\mathbf{H}_t = \mathbf{O}_t \odot \tanh(\mathbf{C}_t). \quad (34)$$

LSTM khắc phục được nhược điểm Suy giảm đạo hàm bằng cách linh hoạt sử dụng cổng đầu vào và cổng quên trong việc cho phép thông tin giữ nguyên hoặc loại bỏ 1 phần thông tin để gradient có thể ổn định khi cần thiết, giúp LSTM học hiệu quả các phụ thuộc dài hạn trong dữ liệu chuỗi.

c. Bidirectional Long Short-Term Memory (Bi-LSTM)

Sepp Hochreiter và Jürgen Schmidhuber đã nhận ra một hạn chế cơ bản của các mô hình RNN truyền thống, bao gồm cả LSTM chuẩn, đó là chúng chỉ khai thác thông tin theo một chiều thời gian từ quá khứ đến hiện tại. Trong nhiều bài toán xử lý chuỗi như nhận dạng chữ viết tay hoặc dịch máy, thông tin trong tương lai cũng đóng vai trò quan trọng trong việc đưa ra dự đoán chính xác. Do đó, nhằm tận dụng ngữ cảnh theo cả hai hướng thời gian, cùng vào năm 1997, các tác giả đã đề xuất mô hình LSTM hai chiều (Bidirectional LSTM – Bi-LSTM), cho phép mô hình đồng thời khai thác thông tin từ quá khứ và tương lai của chuỗi dữ liệu.



Hình 11: Khối Bi-LSTM

Mô hình Bi-LSTM kết hợp 2 mạng LSTM độc lập chạy theo hai chiều thời gian ngược nhau trên cùng một chuỗi đầu vào. Hai mạng LSTM này không chia sẻ trọng số.

Cụ thể, với mạng LSTM theo chiều thuận, chuỗi đầu vào được xử lý từ $\mathbf{x}_1$ đến $\mathbf{x}_T$. Trạng thái ẩn tại thời điểm t , ký hiệu là $\vec{\mathbf{H}}_t$, mang thông tin ngữ cảnh từ quá khứ:

$$\vec{\mathbf{H}}_t = \vec{\mathbf{O}}_t \odot \tanh(\vec{\mathbf{C}}_t) \quad (35)$$

Ngược lại, với mạng LSTM theo chiều nghịch, chuỗi đầu vào được xử lý từ $\mathbf{x}_T$ đến $\mathbf{x}_1$. Trạng thái ẩn tại thời điểm t , ký hiệu là $\overleftarrow{\mathbf{H}}_t$, nắm bắt thông tin ngữ cảnh từ tương lai và được xác định bởi:

$$\overleftarrow{\mathbf{H}}_t = \overleftarrow{\mathbf{O}}_t \odot \tanh(\overleftarrow{\mathbf{C}}_t) \quad (36)$$

Đầu ra của Bi-LSTM tại thời điểm t là kết hợp kết quả của hai trạng thái ẩn theo hai chiều thời gian:

$$\mathbf{H}_t = [\vec{\mathbf{H}}_t; \overleftarrow{\mathbf{H}}_t] \quad (37)$$

Trạng thái ẩn kết hợp này sau đó thường được sử dụng làm đầu vào cho các lớp tiếp theo như các lớp ẩn sau hoặc lớp kết nối đầy đủ trong mô hình.

Dù có ưu điểm khai thác được toàn bộ ngữ cảnh hai chiều của dữ liệu, Bi-LSTM vẫn tồn tại một số hạn chế. Cụ thể, do sử dụng hai mạng LSTM chạy theo hai hướng thời gian ngược nhau, số lượng tham số của mô hình tăng gần gấp đôi, dẫn đến chi phí tính toán và bộ nhớ cao hơn. Bên cạnh đó, Bi-LSTM vẫn giữ đặc tính xử lý tuần tự theo thời gian, vì vậy tốc độ huấn luyện và suy luận bị hạn chế khi áp dụng cho các chuỗi có độ dài lớn.

Đồ án này sử dụng Bi-LSTM ngay sau mô-đun mã hóa âm thanh, với đầu vào là các đặc trưng âm thanh được trích xuất từ wav2vec 2.0. Bi-LSTM xử lý thông tin từ quá khứ đến tương lai và ngược lại, cho phép mô hình khai thác đồng thời ngữ cảnh trước và sau của mỗi khung thời gian. Điều này đặc biệt quan trọng trong nhận dạng tiếng nói, bởi hiện tượng đồng hóa âm (coarticulation) khiến cách phát âm của một âm vị phụ thuộc mạnh vào các âm vị lân cận theo thời gian. Vì vậy, Bi-LSTM đóng vai trò làm mịn và tích lũy ngữ cảnh trước khi đưa vào Transformer Encoder.

2.4.4 Cấu trúc Attention

Một trong những cấu trúc mang tính đột phá nhất trong lĩnh vực học sâu là Transformer, được giới thiệu trong bài báo *Attention is all you need* bởi Vaswani và cộng sự vào năm 2017 [14]. Khác với các kiến trúc trước đó dựa trên RNN hoặc CNN, Transformer sử dụng Scaled dot-product attention để mô hình hóa quan hệ giữa các phần tử trong chuỗi nhằm tăng khả năng xử lý song song và cải thiện việc học các phụ thuộc dài hạn.

Trước đó, Bahdanau et al. (2014) [15] đã đề xuất cơ chế attention trong kiến trúc encoder–decoder dựa trên RNN, trong đó bộ giải mã (decoder) sử dụng attention để tập trung vào các trạng thái ẩn khác nhau của bộ mã hóa (encoder) thay vì nén toàn bộ chuỗi đầu vào vào một vector cố định. Tuy nhiên, cơ chế này vẫn phụ thuộc vào tính tuần tự của RNN, dẫn đến hạn chế trong khả năng song song hóa và làm giảm hiệu quả khi mô hình hóa các chuỗi dài.

Như được giới thiệu trong bài báo về mô hình Transformer, cơ chế attention bao gồm hai dạng chính: Self-attention, cho phép mô hình khai thác mối quan hệ giữa các token trong cùng một chuỗi đầu vào; và cross-attention (hay encoder–decoder attention), trong đó các truy vấn được lấy từ decoder và các khóa, giá trị được lấy từ đầu ra của encoder, cho phép mô hình liên kết thông tin giữa hai chuỗi khác nhau.

a. Self-attention

Phương pháp self-attention có thể được mô hình hóa như sau: Cho dãy đầu vào với độ dài n : $T = [x_1, x_2, \dots, x_n]$, với $x_i \in \mathbb{R}^d$ là véc-tơ nhúng của token thứ i được biểu diễn bởi d chiều. Vậy, ta có thể xem đầu vào như một ma trận:

$$X \in \mathbb{R}^{T \times d} \quad (38)$$

Từ khung ma trận này, có thể khởi tạo ba ma trận trọng số với cùng số chiều:

$$W_Q, W_K, W_V \in \mathbb{R}^{d \times d} \quad (39)$$

Trong đó:

- W_Q là ma trận trọng số của *Query*, biểu diễn thông tin cần được truy vấn;
- W_K là ma trận trọng số của *Key*, biểu diễn thông tin dùng để so khớp với *Query*;
- W_V là ma trận trọng số của *Value*, chứa nội dung thông tin sẽ được tổng hợp dựa trên mức độ tương quan giữa *Query* và *Key*.


Ta thu tập được các ma trận $Q, K, V \in R^{T \times d}$ tương ứng bằng cách nhân ma trận:

$$Q = W_Q X \quad (40)$$

$$K = W_K X \quad (41)$$

$$V = W_V X \quad (42)$$

Hàm attention có thể được mô tả như một ánh xạ từ một query và một tập các cặp key-value tới một đầu ra, trong đó query, key, value và đầu ra đều là các vectơ. Đầu ra được tính bằng tổng có trọng số của các value, trong đó trọng số của mỗi value được xác định thông qua một hàm đo độ tương thích giữa query và key tương ứng. Công thức có thể được mô hình hóa như trong Hình 5:




Hình 12: Scaled Dot-Product Attention

Ta có thể trực quan hóa quá trình như sau:


Nhân ma trận $Q \times K^T$

Với mỗi cặp vector truy vấn–khóa q_i, k_j có kích thước d , ta tính tích vô hướng (dot product) giữa chúng, kết quả là một số vô hướng (scalar) biểu thị điểm chú ý (attention score) của truy vấn đối với khóa đó:



Hình 13: Tích vô hướng (Dot-Product) giữa các vector Truy vấn (Query) và Khóa (Key)

Ta có thể thực hiện các phép toán này hiệu quả hơn bằng cách nhân các ma trận Q và K của chúng:



Hình 14: Tích vô hướng (Dot-Product) giữa các ma trận Truy vấn (Query) và Khóa (Key)

Đầu ra là Ma trận Tương thích QK^T có kích thước $T \times T$

Chuẩn hóa (Scaling)

Ta chia tích vô hướng QK^T cho $\sqrt{d}$, là căn bậc hai của chiều biểu diễn của các vector Query/Key:

$$\frac{QK^T}{\sqrt{d}} \quad (43)$$

Việc chuẩn hóa bằng $\sqrt{d}$ được áp dụng để kiểm soát phương sai của ma trận attention score. Khi chiều của vector khóa d lớn, phương sai này sẽ cao, dẫn đến các giá trị softmax gần bằng 0 và gây ra hiện tượng vanishing gradient trong quá trình huấn luyện.

Áp dụng hàm Softmax


Sau khi chuẩn hóa, ta áp dụng hàm Softmax. Kết quả thu được là một ma trận trong đó tổng các trọng số chú ý giữa mỗi truy vấn và toàn bộ các khóa tương ứng bằng 1.

$$\text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right) \quad (44)$$

Nhân ma trận V

Cuối cùng, ma trận thu được được nhân với ma trận V để tạo ra ma trận trọng số chú ý R . Mỗi hàng của R biểu diễn

một biểu diễn ngữ cảnh của một token đầu vào, được tổng hợp từ các vector giá trị theo mức độ tương thích giữa truy vấn và các khóa tương ứng. Do đó, R còn được gọi là ma trận ngữ cảnh (Context matrix) hoặc ma trận tổng có trọng số của các giá trị (Weighted sum of values).



Hình 15: Phép nhân ma trận giữa ma trận attention weight A và ma trận giá trị V


Toàn bộ quá trình trên có thể được biểu diễn gọn:

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V \quad (45)$$

Cấu trúc Self-attention thường được sử dụng trong các khối mã hóa hoặc giải mã hiện nay như Transformer Encoder/Decoder, với vai trò tổng hợp và bổ sung thông tin về ngữ cảnh cho các token dữ liệu đầu vào.

b. Cross-attention

Trong cơ chế scaled dot-product self-attention, các ma trận truy vấn Q , khóa K và giá trị V đều được trích xuất từ cùng một chuỗi đầu vào X . Ngược lại, cơ chế cross-attention được thiết kế nhằm cho phép một chuỗi Y tập trung vào các phần tử của một chuỗi khác X . Trong trường hợp này, ma trận truy vấn Q được tính từ chuỗi Y , trong khi các ma trận khóa K và giá trị V được tính từ chuỗi X . Ngoài trừ sự khác biệt về nguồn sinh ra của các ma trận Q , K và V . Sau khi thu được các ma trận Q , K và V , các phép tính tiếp theo được thực hiện tương tự như trong cơ chế self-attention.




Hình 16: Sự khác biệt giữa nguồn đầu vào của các ma trận Query, Key và Value trong cơ chế self-attention và cross-attention

c. Multihead-attention

Thay vì chỉ thực hiện một hàm chú ý duy nhất với các ma trận truy vấn, khóa và giá trị với d chiều biểu diễn, cơ chế multi-head attention sử dụng n phép chiếu tuyến tính khác nhau để ánh xạ các ma trận truy vấn, khóa và giá

trị sang các không gian có kích thước lần lượt là d_k , d_k và d_v . Trên mỗi phiên bản đã được chiếu tuyến tính của các ma trận truy vấn, khóa và giá trị này, hàm chú ý được thực hiện song song, tạo ra các đầu ra có chiều d_v . Các đầu ra này sau đó được nối lại (concatenate) và tiếp tục được chiếu tuyến tính một lần nữa để thu được biểu diễn đầu ra cuối cùng, như minh họa trong Hình 10.



Hình 17: Multi-head Attention

Cơ chế multi-head attention cho phép mô hình đồng thời tập trung vào thông tin từ các không gian biểu diễn khác nhau tại các vị trí khác nhau trong chuỗi. Ngược lại, với một đầu attention duy nhất, quá trình lấy trung bình có thể làm hạn chế khả năng này. Cơ chế này có thể được mô hình hóa như sau:

$$MultiHead(Q, K, V) = Concat(h_1, h_2, \dots, h_n) \cdot W_O \quad (46)$$

Với $h_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$

Các phép chiếu này được tham số hóa bởi các ma trận:

$$\begin{aligned} W_Q^i &\in \mathbb{R}^{d_{\text{model}} \times d_k}, \\ W_K^i &\in \mathbb{R}^{d_{\text{model}} \times d_k}, \\ W_V^i &\in \mathbb{R}^{d_{\text{model}} \times d_v}, \\ W_O &\in \mathbb{R}^{hd_v \times d_{\text{model}}}. \end{aligned} \quad (47)$$

Trong đồ án này, cơ chế cross-attention sẽ được sử dụng với phương pháp multihead-attention nhằm căn chỉnh mềm giữa đoạn âm thanh đầu vào và dãy âm vị gốc thay vì căn chỉnh cường bức.


2.4.5 Cấu trúc Transformer Encoder

Trong bài toán biến đổi chuỗi, encoder-decoder thường là kiến trúc phổ biến. Trong đó, bộ mã hóa (encoder) ánh xạ một chuỗi đầu vào gồm các ký tự hoặc từ $(x_1, \dots, x_n)$ thành một chuỗi các biểu diễn liên tục $\mathbf{z} = (z_1, \dots, z_n)$.

Bộ mã hóa (encoder) bao gồm một chồng N lớp giống hệt nhau. Mỗi lớp gồm hai phân lớp: Multi-head Attention và một lớp truyền thẳng (Feed-forward network); Sau mỗi lớp sẽ có thêm một khối kết nối dư (residual connection) và chuẩn hóa lớp (layer normalization). Cụ thể, đầu ra của mỗi phân lớp được tính theo:

$$\text{LayerNorm}(x + \text{Sublayer}(x)), \quad (48)$$

Trong đó $\text{Sublayer}(x)$ là hàm được hiện thực bởi phân lớp tương ứng. Để hỗ trợ các kết nối dư này, tất cả các phân lớp trong mô hình, cũng như các lớp embedding, đều tạo ra các biểu diễn có cùng kích thước d_{model} .




Hình 18: Cấu trúc Transformer Encoder

2.4.6 Framework Wav2vec 2.0

Là một mô hình học sâu dạng encoder được sử dụng trong mã hóa âm thanh thành vector biểu diễn, được phát triển bởi Facebook vào năm 2020 với mục tiêu tạo ra các biểu diễn ẩn có ý nghĩa hơn, đồng thời giảm thiểu đáng kể khối lượng dữ liệu có gắn nhãn cần phải sử dụng cho quá trình fine-tune sử dụng học có giám sát.

Mô hình được huấn luyện theo hướng self-supervised nhằm trả về các vector biểu diễn từ các đoạn ghi âm gốc. Xét về cách hoạt động ở mức tổng quan, mô hình nhận vào đoạn âm thanh và mã hóa nó sử dụng một khối có cấu trúc CNN đa lớp và ẩn (mask) một số đoạn trên biểu diễn âm thanh thu được từ khối này. Các biểu diễn âm thanh sau đó được đưa vào một mạng Transformer để bổ sung thông tin về ngữ cảnh. Mô hình được huấn luyện theo hướng tác vụ tương phản (contrastive task) với mục tiêu học là nhận diện biểu diễn tiềm ẩn chính xác và phân biệt với các biểu diễn gây nhiễu khác (distractor representations).



Hình 19: Cấu trúc framework wav2vec 2.0

Cấu trúc của wav2vec 2.0 có thể được mô hình hóa như sau:

- Khối mã hóa nơ-ron tích chập CNN đa lớp $f : X \rightarrow Z$ nhận vào đoạn âm thanh gốc X và trả về biểu diễn ẩn $Z : z_1, z_2, \dots, z_T$ với T là số khung âm thanh trong đoạn X .
- Khối Transformer $g : Z \rightarrow C$ nhận vào đoạn Z này và bổ sung thông tin từ toàn đoạn nhằm tạo ra biểu diễn $C : c_1, c_2, \dots, c_T$.
- Bên cạnh đó, đầu ra Z cũng được rời rạc hóa (discretized) thành dãy q_t sử dụng một mô-đun lượng tử hóa (quantization module) $Z \rightarrow Q$. Dãy q_t sẽ được sử dụng làm mục tiêu huấn luyện của quá trình học tự giám sát.

Cụ thể hơn:

Khối mã hóa đặc trưng (Feature encoder): Âm thanh đầu vào dạng waveform sẽ được chuẩn hóa với trung bình = 0 và độ lệch chuẩn = 1 trước khi chạy qua các khối nơ-ron tích chập – layer normalization – hàm activation GELU được xếp song song. Số khung âm thanh T được xác định bởi số bước nhảy của các khối nơ-ron tích chập song song này. Trong quá trình huấn luyện, đầu ra Z sẽ được chạy qua một hàm masking trước khi được truyền vào lớp tiếp theo.

Biểu diễn theo ngữ cảnh với Transformer: Đầu ra của khối mã hóa đặc trưng Z sẽ được truyền vào một mạng CNN nối tiếp với một hàm activation GELU và tạo ra dãy kết quả Z' . Đầu ra của hàm này Z' sẽ được cộng với Z và chạy qua một lớp layer normalization. Z' đóng vai trò làm cơ chế mã hóa vị trí tương đối (relative positional encoding) thay cho cơ chế mã hóa vị trí thông thường sử dụng vị trí tuyệt đối. Kết quả sẽ được đưa vào lớp Transformer nhằm bổ sung ngữ cảnh.

Lớp lượng tử hóa (Quantization): Lớp này sẽ chỉ được sử dụng trong quá trình huấn luyện với vai trò tạo ra mục tiêu huấn luyện tự giám sát. Lớp này nhận vào Z từ khối mã hóa đặc trưng và sử dụng nó để tính toán các biểu diễn rời rạc q bằng phương pháp product quantization kết hợp Gumbel-Softmax, trong đó mỗi khung thời gian được ánh xạ tới một tổ hợp hữu hạn các vector mã từ nhiều nhóm mã khác nhau. Các biểu diễn rời rạc này đóng vai trò là nhãn giả (pseudo-labels) cho bài toán học tự giám sát.

Sau khi hoàn tất quá trình huấn luyện tự giám sát, mô-đun lượng tử hóa và cơ chế masking sẽ được loại bỏ. Khối mã hóa đặc trưng và mạng Transformer được giữ lại và fine-tune cho các tác vụ khác.

Trong đồ án này, mô hình được xây dựng sử dụng mô-đun wav2vec2 đã được huấn luyện trước khoảng 53.000 giờ dữ liệu âm thanh không gán nhãn từ bộ dữ liệu Libri-Light và với vector biểu diễn 1024 chiều.

CHƯƠNG 3. XÂY DỰNG MÔ HÌNH VÀ HỆ THỐNG

3.1 Kiến trúc mô hình

3.1.1 Định nghĩa bài toán

Bài toán nhận diện lỗi phát âm và phản hồi được mô hình hóa như sau:

Cho:

- Đoạn âm thanh có độ dài T : $x = (x_1, x_2, \dots, x_T)$ biểu thị lời nói ghi được từ người học.
- Đoạn văn bản đối chiếu người học cần nói được chuyển đổi thành đoạn âm vị tương ứng với độ dài N :
 $q = (q_1, q_2, \dots, q_N)$

Với mục tiêu của mô hình được xác định:

- Xác định được dãy trạng thái lỗi (error state sequence) với độ dài N : $e = (e_1, e_2, \dots, e_N)$, với 0 biểu thị âm vị sai và 1 biểu thị âm vị đúng
- Dự đoán dãy âm vị độ dài N' : $y = (y_1, y_2, \dots, y_{N'})$ phản ánh chính xác phát âm từ đoạn ghi âm x

3.1.2 Thành phần mô hình

Mô hình được cấu thành bởi năm thành phần chính:

- **Mô-đun mã hóa âm vị:** Thực hiện trích xuất chuỗi biểu diễn $\mathbf{S}$, là biểu diễn một chiều theo thời gian của dãy âm vị đích $\mathbf{q}$ với độ dài N .
- **Mô-đun mã hóa âm thanh:** Sử dụng wav2vec 2.0 để trích xuất chuỗi biểu diễn $\mathbf{H}$, phản ánh đặc trưng phát âm của người học từ dãy tín hiệu âm thanh đầu vào $\mathbf{x}$.
- **Mạng attention:** Thực hiện căn chỉnh mềm giữa hai chuỗi $\mathbf{S}$ và $\mathbf{H}$, tạo ra chuỗi biểu diễn đã căn chỉnh $\mathbf{C}$ có độ dài N .
- **Mô-đun phát hiện lỗi:** Nhận đầu vào là $\mathbf{C}$ kết hợp với $\mathbf{S}$ và sinh ra chuỗi đánh dấu lỗi $\mathbf{e}$ có độ dài N .
- **Mô-đun dự đoán âm vị:** Thực hiện chẩn đoán bằng cách suy luận chuỗi âm vị $\mathbf{y}$ có độ dài N' từ tín hiệu âm thanh đầu vào đã được mã hóa $\mathbf{H}$.

Tổng quan thiết kế của mô hình được mô tả trong Hình 20. Trong đó:

a. Mô-đun mã hóa âm vị đích

Các ký tự âm vị đích $q = (q_1, q_2, \dots, q_N)$ được mã hóa nhúng sử dụng embedding layer pytorch. Cụ thể hơn, với dãy âm vị đầu vào q_i , ta nhận được véc-tơ ánh xạ embedding s_i . Toàn bộ dãy âm vị được biểu diễn bởi:

$$\mathbf{S} = \text{Embedding}(\mathbf{q}) = (s_1, s_2, \dots, s_N) \quad (49)$$

Với các phần tử: $s_i = \text{Embedding}(q_i)$ với $i = 1, 2, \dots, N$

b. Mô-đun mã hóa âm thanh

Đoạn âm thanh đầu vào $x = (x_1, x_2, \dots, x_T)$ được mã hóa bằng bộ trích xuất đặc trưng wav2vec 2.0 với trọng số đã được huấn luyện trước, nhằm thu được dãy biểu diễn khung âm thanh:

$$H = Enc_{w2v2}(x) = (h_1, h_2, \dots, h_T) \quad (50)$$

Với các phần tử: $h_t = Enc_{w2v2}(x_t)$ với $t = 1, 2, \dots, T$

c. Mạng attention căn chỉnh mềm (soft alignment)

Một khối multi-head attention được sử dụng để căn chỉnh mềm giữa dãy âm vị đích nhúng E và dãy đặc trưng âm thanh H . Trong đó, dãy S đóng vai trò Query, còn dãy H đóng vai trò Key và Value. Ta có:

$$Q_i = W_Q \cdot s_i, K_t = W_K \cdot h_t, V_t = W_V \cdot h_t \quad (51)$$

Với:

- Q_i : vector truy vấn tại vị trí i của dãy E
- K_t : vector khóa tại vị trí t của dãy H
- V_t : vector giá trị tại vị trí t của dãy H
- W_Q, W_K, W_V : ma trận trọng số có thể học được (trainable weight matrices)

Từ đó tính được trọng số attention cho âm vị đích thứ i , kí hiệu là $a_{i,t}$:

$$a_{i,t} = Softmax_t\left(\frac{Q_i^\top \cdot K_t}{\sqrt{d}}\right) \quad (52)$$

Với d là số chiều biểu diễn (feature dimension) của vector Q_i hay K_i .

Và nhận được vector ngữ cảnh c_i tương ứng:

$$c_i = \sum_{t=1}^T a_{i,t} V_t \quad (53)$$

Kết quả thu được là dãy các vector ngữ cảnh: $C = (c_1, c_2, \dots, c_N)$

d. Mô-đun phát hiện lỗi (Error state detector)

Là một mạng lưới MLP bao gồm ba lớp linear, giữa các lớp có hàm kích hoạt GELU và dropout. Mạng nhận vào vector z_i là kết hợp giữa dãy nhúng của âm vị s_i và véc-tơ ngữ cảnh c_i và trả về phân phối xác suất hậu nghiệm cho trạng thái lỗi của âm vị tại vị trí i :

$$P(e_i|x, q_i) = Softmax(MLP(z_i = [s_i; c_i])) \quad (54)$$

Toàn bộ dãy trạng thái lỗi có thể được mô hình hóa bởi:

$$P(e|x, q) = \prod_{i=1}^N P(e_i|x, q_i) \quad (55)$$

Trong đó, $P(e_i|x, q_i)$ được hiểu là xác suất hậu nghiệm biểu thị âm vị thứ i ở trạng thái lỗi, khi biết đoạn âm thanh x và âm vị đích q_i .

e. Mô-đun dự đoán âm vị

Mô-đun có nhiệm vụ nhận biết các âm vị mà người học đã phát âm trong đoạn âm thanh. Đầu vào lấy dãy đặc trưng âm thanh H , sau đó lần lượt đi qua một khối LSTM hai chiều và một khối Transformer. Cuối cùng, một lớp Linear

được sử dụng để ánh xạ đầu ra của Transformer thành dãy $Y = (y_1, y_2, \dots, y'_N)$ là xác suất hậu nghiệm của tất cả các âm vị tại mỗi khung âm thanh:

$$\hat{H} = \text{Transformer}(\text{BiLSTM}(H)) \quad (56)$$

$$P(y_t|x) = \text{Softmax}(\text{Linear}(\hat{h}_t)) \quad (57)$$

Với $t = 1, 2, \dots, T$, $P(y_t|x)$ là xác suất khung âm thanh tại thời điểm t nhận giá trị âm vị y_t khi biết đoạn âm thanh đầu vào x .

Qua đó ta thu được tập hợp $A(y) = \{\pi_1, \pi_2, \dots, \pi_j\}$ với mỗi π là một dãy âm vị mà sau khi đã loại bỏ các âm vị lặp và ký tự rỗng, tương ứng với dãy âm vị đích, phục vụ cho quá trình tính toán với hàm mất mát CTC.

f. Hàm mất mát

Hai mô đun dự đoán âm vị và phát hiện lỗi được huấn luyện kết hợp, với CTC (Connectionist Temporal Classification) [7] và NLLoss (Negative Log-Likelihood Loss), trong đó:

Mô đun dự đoán âm vị: Với $A(y)$ là tập hợp các dãy căn chỉnh CTC hợp lệ, ta có:

$$P(y|x) = \sum_{\pi \in A(y)} \prod_{t=1}^T P(\pi_t|x) \quad (58)$$

$$\mathcal{L}_{CTC} = -\log P(y|x) \quad (59)$$


Mô đun phát hiện lỗi: Hàm mất mát NLL được định nghĩa bởi hàm negative log likelihood của tất cả các trạng thái lỗi của các âm vị.

$$\mathcal{L}_{NLL} = -\sum_{i=1}^N \log P(e_i|x, q_i) \quad (60)$$

Hai mô đun này được kết hợp tuyến tính (linearly combined) thành hàm mất mát tổng của mô hình:

$$\mathcal{L} = \alpha_{CTC} \cdot \mathcal{L}_{CTC} + \alpha_{NLL} \cdot \mathcal{L}_{NLL} \quad (61)$$

Với α_{CTC} và $\alpha_{NLL} \in [0, 1]$ là tham số tùy chỉnh giúp điều khiển ưu tiên learning objective giữa hai mô đun.



Hình 20: Sơ đồ cấu trúc mô hình PB-MDD-TA

3.2 Thu thập và xử lý dữ liệu

3.2.1 Yêu cầu đầu vào của mô hình

Đối với các đặc trưng đầu vào:

Âm thanh đầu vào (x):

- Định dạng: Định dạng .wav 1 kênh với sampling rate 16kHz
- Độ dài: Trong khoảng từ 1 đến 25 giây

Dãy âm vị gốc (q):

- Là các dãy ký tự dưới dạng ARPABET được chuyển đổi từ văn bản gốc, biểu thị chính xác những âm tiết người học cần phải nói. Chi tiết các âm vị tiêu chuẩn trong ARPABET được nêu trong phụ lục A.

Đối với giá trị mục tiêu:

- Dây âm vị mục tiêu (y): Dây ký tự ARPABET biểu thị chính xác những âm tiết người nói đã tạo ra trong đoạn ghi âm. Mô-đun nhận diện âm vị cần phải dự đoán chính xác mục tiêu này.
- Dây đánh dấu lỗi (e): Dây đánh dấu lỗi cần phản ánh chính xác sự tương đồng và khác biệt giữa dây âm vị mục tiêu (y) và dây âm vị gốc (q), sau đó, đánh nhãn 0 với âm vị sai và 1 với âm vị chính xác.

3.2.2 Các bộ dữ liệu được sử dụng

Dựa trên các yêu cầu dữ liệu đầu vào trên, nhóm đã tìm và Thu thập được các bộ dữ liệu tương ứng có thể phục vụ cho quá trình huấn luyện và đánh giá mô hình.

a. L2-ARCTIC

L2-ARCTIC là bộ dữ liệu bao gồm các bản ghi âm lời nói tiếng Anh của các tình nguyện viên không bản ngữ, được sử dụng nhiều trong các nghiên cứu xử lý tiếng nói và là một bộ dữ liệu thường được dùng để làm benchmark cho các mô hình MDD. Bộ dữ liệu bao gồm lời nói tiếng Anh của 24 người có ngôn ngữ gốc là Hindi, Hàn, Trung Phổ Thông, Tây Ban Nha, Ả Rập và Việt Nam, với mỗi ngôn ngữ gốc bao gồm 2 nam và 2 nữ. Đối với mỗi người nói, tập ngữ liệu bao gồm các dữ liệu sau:

- **Các đoạn ghi âm:** Mỗi tình nguyện viên đóng góp hơn một giờ ghi âm theo mẫu (khoảng 1132 câu), bao gồm các câu ngắn được cân bằng theo độ đa dạng của âm vị. Các file ghi âm có định dạng .wav 1 kênh với sampling rate 16kHz. Tuy nhiên, chỉ có khoảng 5000 bản ghi đã được kiểm tra và chú thích thủ công phù hợp với bài toán MDD.
- **Phiên âm cấp độ từ:** Phiên âm chính tả và các mốc biên từ được căn chỉnh tự động cho mỗi câu
- **Phiên âm cấp độ âm vị:** Phiên âm âm vị được căn chỉnh tự động cho mỗi câu, sử dụng cả hai chuẩn ARPABET và IPA
- **Chú thích thủ công:** Một tập con được chọn của các phát ngôn (khoảng 150 câu), gồm 100 câu được tất cả người nói đọc và 50 câu chứa các âm vị được dự đoán là khó đối với L1 của từng người nói; tất cả đều được chú thích với biên từ và biên âm vị đã chỉnh sửa; lỗi thay thế, xóa, và thêm âm vị cũng được gắn nhãn. Trong báo cáo này, sẽ chỉ sử dụng những bản ghi đã được đánh nhãn.

b. TIMIT

TIMIT là bộ dữ liệu ghi âm lời nói tiếng Anh bản ngữ, được phát triển thông qua hợp tác giữa MIT, SRI International và Texas Instruments. Ghi âm được thực hiện tại TI, phiên âm tại MIT và kiểm định bởi NIST. Bộ dữ liệu bao gồm khoảng 5 giờ lời nói tiếng Anh đã được căn chỉnh thời gian và kiểm tra thủ công, được thiết kế phục vụ nghiên cứu âm học–âm vị học và phát triển cũng như đánh giá các hệ thống nhận dạng tiếng nói tự động. TIMIT chứa các bản ghi băng rộng của 630 người nói thuộc tám phương ngữ chính của tiếng Anh Mỹ (khoảng 70% nam, 30% nữ), mỗi người đọc 10 câu giàu âm vị. TIMIT được thiết kế để cung cấp dữ liệu phục vụ nghiên cứu âm học–âm vị học và phát triển cũng như đánh giá các hệ thống nhận dạng tiếng nói tự động.

Đối với mỗi bản ghi, tập dữ liệu bao gồm các thành phần sau:

- **Đoạn ghi âm:** File âm thanh đơn kênh, 16-bit, 16 kHz cho từng câu đọc.
- **Phiên âm chính tả (word transcription):** Phiên âm từ vựng được căn chỉnh theo thời gian cho mỗi phát ngôn.
- **Phiên âm âm vị (phonetic transcription):** Phiên âm âm vị được căn chỉnh theo thời gian, phục vụ nghiên cứu cấu trúc âm học–âm vị học.
- **Tập huấn luyện và kiểm tra:** Được thiết kế cân bằng về độ bao phủ âm vị và phương ngữ, hỗ trợ đánh giá mô hình nhận dạng tiếng nói.
- **Dữ liệu nhân khẩu học của người nói:** Gồm giới tính, phương ngữ, ngày sinh, chiều cao, chủng tộc và trình độ học vấn, phục vụ phân tích nhân khẩu học trong các nghiên cứu liên quan đến tiếng nói.

c. SpeechOcean762

SpeechOcean762 là bộ dữ liệu đánh giá phát âm của người học tiếng Anh L2 được phát triển bởi Xiaomi và SpeechOcean, chuyên sử dụng trong việc phát triển các hệ thống CAPT dựa trên chấm điểm. Bộ dữ liệu được phát triển nhằm giải quyết vấn đề khan hiếm nguồn dữ liệu miễn phí trong lĩnh vực xử lý tiếng nói. Bộ bao gồm gần 5000 phát ngôn từ 250 người có ngôn ngữ gốc là Tiếng Trung Phổ Thông, trong số đó, tỉ lệ giới tính là 1:1, với một 40% số người trong độ tuổi từ 6-16 và 60% trong độ tuổi từ 17-45 có trình độ tiếng Anh khác nhau. Mỗi người nói đọc to các đoạn văn bản tiếng Anh được cung cấp, ghi âm bằng điện thoại di động (nhiều mẫu khác nhau) trong một căn phòng yên tĩnh. Gồm 20 câu khác nhau với độ dài từ 1 đến 27 giây.

Mỗi phát ngôn được chấm và gán nhãn ở nhiều mức độ bởi năm chuyên gia:

- Phiên âm mức câu/từ: được chấm trên tiêu chí độ chính xác, độ đầy đủ, độ trôi chảy và ngữ điệu.
- Phiên âm mức âm vị: Mỗi âm vị trong đoạn được đánh nhãn từ 0 đến 2, với 0 là sai hoặc bị bỏ qua, 1 là đúng nhưng chứa nhiều giọng địa phương, và 2 là đúng.

Bên cạnh đó, mỗi bản ghi cũng bao gồm các trường liên quan đến nhân khẩu học của người nói.

d. Mozilla Common Voice

Common Voice là một tập dữ liệu chứa ghi âm lời nói từ người dùng trên nền tảng CommonVoice của Mozilla. Tập dữ liệu này bao gồm nhiều phiên bản, với mỗi phiên bản tương ứng với collection bản ghi trong một quý hoặc một năm. Âm thanh bao gồm giọng nói được thu âm từ máy tính cá nhân và văn bản cần đọc tương ứng, lấy từ các nguồn thuộc phạm vi công cộng như blog, sách, phim và các bộ dữ liệu lời nói khác. Tập dữ liệu này được phát triển nhằm hỗ trợ hoặc tăng cường các hệ thống nhận dạng tiếng nói (ASR).

Về cấu trúc, với mỗi phiên bản, tập dữ liệu được chia thành 3 phần dựa trên quá trình xác thực của cộng đồng. Âm thanh được ghi và lưu dưới dạng .mp3 với sampling rate 16kHz. Các đoạn âm thanh được đánh nhãn như sau: Các đoạn âm thanh “valid” có ít nhất hai người nghe xác nhận rằng phát âm khớp với văn bản. Các đoạn “invalid” có ít nhất hai phiếu cho rằng phát âm không trùng khớp. Những đoạn có ít hơn hai phiếu hoặc số phiếu ngang nhau được xếp vào nhóm “other”. Mỗi bản ghi chứa đoạn âm thanh cùng với đoạn văn bản tương ứng và thông tin nhân khẩu học của người nói như tuổi, giới tính và chất giọng.

Đồ án này sử dụng 18000 bản ghi được đánh nhãn “valid” từ ba tập phiên bản dữ liệu mới nhất.

e. Dữ liệu nói tiếng Anh từ học viên Việt Nam

Dữ liệu lời nói tiếng Anh được Thu thập từ một trung tâm giáo dục trực tuyến, chuyên giảng dạy tiếng Anh thông dụng và luyện thi các chứng chỉ tiếng Anh như TOEFL, IELTS. Việc sử dụng bộ dữ liệu này trong phát triển mô hình đã được ủy quyền bởi trung tâm.

- **Chất lượng âm thanh:** Các đoạn âm thanh được ghi âm bởi bộ ghi âm thông dụng trong phòng thi nói tiếng Anh hoặc ghi từ máy tính hay smartphone cá nhân của người học với chất lượng và tiếng ồn nền đa dạng.
- **Số lượng bản ghi:** Dữ liệu bao gồm 4000 bản ghi với độ dài trung bình 12 giây.

Dữ liệu được tiền xử lý bằng công cụ SpeechAceAPI, là một dịch vụ CAPT mã nguồn đóng giúp phân tích lời nói từ các đoạn ghi âm và trả về kết quả so sánh giữa đoạn âm vị gốc và đoạn âm vị trích xuất được. Bộ dữ liệu này sẽ được sử dụng để tinh chỉnh mô hình sao cho phù hợp hơn với người học tiếng Anh có bản ngữ là tiếng Việt.

3.2.3 Tiền xử lý, phân tích và tăng cường dữ liệu

Phương pháp sử dụng dữ liệu:

Trong 5 tập dữ liệu kể trên, bộ dữ liệu L2-Arctic sẽ được sử dụng làm dữ liệu chính nhằm tinh chỉnh và đánh giá hiệu quả của kiến trúc mô hình. Ba bộ dữ liệu TIMIT, SpeechOcean762, Mozilla Common Voice sẽ được sử dụng cho phương pháp tăng cường dữ liệu nhằm tạo ra các nhân lỗi mới. Bên cạnh đó, bộ dữ liệu tiếng Anh từ học viên Việt Nam sẽ được sử dụng cho bước tinh chỉnh mô hình sao cho phù hợp với ngữ điệu của người học tiếng Anh có ngôn ngữ gốc là tiếng Việt.

a. L2-ARCTIC


Đối với bộ dữ liệu L2-ARCTIC, ta có thể trích xuất được các thông tin sau:

- Số bản ghi: 5000
- Các trường thông tin:
 - Audio: Các bit âm thanh được trích xuất
 - Canonical: Âm vị gốc (q)
 - Transcript: Âm vị đích (y)

Dãy đánh dấu lỗi âm vị được tạo ra bằng cách căn chỉnh dãy q và y sử dụng thuật toán Needleman–Wunsch sau đó đánh nhãn 0 cho các vị trí âm vị chứa lỗi. Hình 21 biểu thị cách tạo dãy đánh dấu lỗi, trong đó “Op” biểu thị loại lỗi (M: Match, S: Substitution, D: Deletion, I: Insertion). Mô đun nhận diện lỗi sẽ tập trung vào nhận diện 2 loại lỗi chính là thiếu âm (Deletion) và sai âm (Substitution), còn lỗi thêm âm (Insertion) sẽ được nhận diện bằng mô đun dự đoán âm vị.

Canonical	SH	IY	T	ER	N	D	IH	N	AE	T	-	DH	AH	HH	OW	T	EH	L
Transcript	SH	IY	T	AH	N	-	IY	N	-	T	UW	D	AH	HH	OW	T	EH	W
Op	M	M	M	S	M	D	S	M	D	M	I	S	M	M	M	M	M	S
Error	1	1	1	0	1	0	0	1	0	1	-	0	1	1	1	1	1	0

Hình 21: Phương pháp tạo dãy đánh dấu lỗi sử dụng thuật toán căn chỉnh Needleman—Wunsch.
Câu đối chiếu: “She turned in at the hotel”.



Hình 22: Bảng phân bố tần suất lỗi phát âm trong bộ dữ liệu L2-ARCTIC.

Kết quả dữ liệu được làm sạch có thể được tìm thấy tại <https://huggingface.co/datasets/MinhLe999/ArcticL2TestReplica>.

Tần suất và phân bố nhân

Thông thường, các tập dữ liệu phân tích lỗi phát âm sẽ có sự thiên lệch đáng kể về phía nhân dữ liệu đúng. Điển hình trong bộ dữ liệu L2-ARCTIC, với 80% số nhân đúng và 20% sai. Ta cũng thu được bảng tần suất phân bố lỗi phát âm như hình 22.

b. TIMIT, Mozilla Common Voice

Do hai bộ dữ liệu này chỉ chứa đoạn âm thanh và câu gốc tương ứng nên sẽ được sử dụng nhằm tăng cường cho mô hình. Cụ thể, với dãy âm vị gốc (q), thay thế 45% số âm vị trong dãy bằng các âm vị khác theo quy tắc phân bố trong Hình 22 thu được từ bộ L2-ARCTIC. Ví dụ, với dãy âm vị gốc (q) là $[AA, P, AH, L]$, ta tra bảng phân bố lỗi và nhận thấy người học L2 thường mắc lỗi $B \rightarrow P$. Do đó, ta chỉnh dãy thành $[AA, B, AH, L]$, khiến âm P được xem như đã phát âm sai. Qua đó thu được dãy âm vị gốc mới (q_{new}) và sử dụng dãy âm vị gốc (q) gốc làm dãy âm vị đích mới (y_{new}).

Kết quả dữ liệu được làm sạch và tăng cường của hai bộ dữ liệu kể trên có thể được tìm thấy tại:

<https://huggingface.co/datasets/MinhLe999/MozillaBoost3>.

<https://huggingface.co/datasets/MinhLe999/TIMITBoost3>.

c. SpeechOcean762

Đối với bộ dữ liệu SpeechOcean762, ta có thể trích xuất được các thông tin sau:

- Số bản ghi: 4000
- Các trường thông tin:
 - Audio: Các bit âm thanh được trích xuất
 - Canonical: Âm vị gốc (q)
 - Phone score: Chấm điểm âm vị trên thang 0-2

Khác với L2-ARCTIC, bộ dữ liệu này chỉ chứa dữ liệu âm vị được chấm điểm nhưng không nêu chính xác những âm vị đã được phát âm bởi người nói, vì vậy nhóm đã sử dụng một mô hình ASR dành cho âm vị được huấn luyện sẵn nhằm trích xuất chính xác âm vị đã được tạo ra trong các đoạn ghi âm của bộ dữ liệu này, từ đó thu được dãy âm vị đích (y). Sau đó, căn chỉnh dãy âm vị này (y) với dãy Âm vị gốc (q) bằng Needleman–Wunsch. Dựa trên kết quả căn chỉnh, nhóm lần lượt kiểm tra từng âm vị trong q và đối chiếu với giá trị điểm lỗi tương ứng. Với những âm vị có điểm số lớn hơn 1, nhóm thay thế âm vị trong chuỗi đích (y) bằng âm vị gốc tương ứng trong q. Bên cạnh đó, bộ dữ liệu cũng được tăng cường bằng phương pháp đã được nêu trong phần b. Cụ thể, nhóm đã chọn ngẫu nhiên các đoạn phát âm đúng và thay thế 45% số ký hiệu âm vị trong văn bản tương ứng bằng các âm vị khác theo quy tắc phân bố trong Hình 22 thu được từ bộ L2-ARCTIC. Kết quả dữ liệu được làm sạch và tăng cường của hai bộ dữ liệu kể trên có thể được tìm thấy tại:

<https://huggingface.co/datasets/MinhLe999/SpeechOceanBoost3>.

3.3 Thí nghiệm và kết quả

3.3.1 Cấu hình dữ liệu huấn luyện

a. Đối với thí nghiệm phát triển mô hình

Với bộ dữ liệu L2-ARCTIC, trong 24 người, dữ liệu của 6 người nói (NJS, TLV, TNI, TXHC, YKWK, ZHAA) được tách làm tập kiểm tra, còn dữ liệu của 18 người nói còn lại được gộp lại để tạo thành tập huấn luyện. Ngoài ra, một tập phát triển (development set) được tạo bằng cách chọn ngẫu nhiên 20% số câu từ mỗi người nói trong tập huấn luyện. Hai tập huấn luyện và phát triển hoàn toàn không trùng nhau.

Với mỗi bộ dữ liệu đã được tăng cường trong 3 bộ dữ liệu TIMIT, MozillaCommonVoice, SpeechOcean sẽ được trích 200 bản ghi mỗi bộ làm tập kiểm tra và 100 bản ghi cho tập phát triển trong quá trình huấn luyện.

Kết quả đầu ra cuối cùng sẽ được kiểm tra với dữ liệu của 6 người nói trong tập kiểm tra của bộ dữ liệu L2-ARCTIC nhằm so sánh với các mô hình MDD hiện tại đã được phát triển: GOP, CNN-RNN-CTC, PEPPANET, PG-MDD.

b. Đối với mô hình sử dụng trong thực tiễn

Để đưa mô hình vào ứng dụng thực tiễn, nhóm đã fine-tune mô hình đã được huấn luyện trong thí nghiệm phát triển mô hình với dữ liệu nói tiếng Anh từ học viên Việt Nam. Trong 4400 bản ghi, 100 bản ghi sẽ được trích làm tập kiểm tra và 100 bản ghi cho tập phát triển.

Bên cạnh đó, ba bộ dữ liệu TIMIT, MozillaCommonVoice, SpeechOcean gốc cũng được tăng cường dựa trên bảng phân bố lỗi thu được từ bộ dữ liệu nói tiếng Anh từ học viên Việt Nam.

3.3.2 Cấu hình mô hình

Mô hình được huấn luyện sử dụng thư viện PyTorch và Huggingface wrapper. Quá trình huấn luyện được thực hiện trên GPU NVIDIA A100 với cấu hình siêu tham số như sau:

- **Số Epoch:**
 - 5 epoch huấn luyện trên cả 4 tập: L2-ARCTIC, TIMIT, MozillaCommonVoice, SpeechOcean
 - 15 epoch huấn luyện lại trên tập L2-ARCTIC
- **Kích thước batch:** 8
- **Learning rate:**
 - Mô hình wav2vec2: 3×10^{-5}
 - Mô-đun dự đoán âm vị: 1×10^{-3}
 - Mô-đun nhận diện lỗi: 1×10^{-3}
 - Lớp căn chỉnh mềm: 1×10^{-3}
 - Lớp embedding (q): 1×10^{-4}
- **Trọng số:**
 - $\lambda_{ctc} = 0.2$
 - $\lambda_{nll} = 0.8$
- **Optimizer:** AdamW
- **Weight decay:** 1×10^{-2}

Để khắc phục sự mất cân bằng nhãn trong thực tế, nhóm đã bổ sung trọng số nhãn cho mô-đun nhận diện lỗi:

- Nhãn 0: 2.5
- Nhãn 1: 1.0

Đối với mô-đun audio encoder, nhóm sử dụng mô hình wav2vec2-large của Facebook, được huấn luyện với bộ dữ liệu Librispeech 960h cho tác vụ ASR tiếng Anh bản ngữ, và đã được fine-tune trước cho tác vụ nhận dạng âm vị trong 10 epoch với bộ dữ liệu TIMIT, sử dụng cùng train/test setup như trong thí nghiệm này. Weight của lớp feature_extractor sẽ được đóng băng.

3.3.3 Kết quả thực nghiệm

a. Các tiêu chí đánh giá

Trong mô hình MDD, tiêu chí đánh giá chính tập trung vào cân bằng giữa số lỗi nhận dạng được và giảm thiểu tối đa *false negatives*, do đó chỉ số F1 được chọn làm tiêu chí đánh giá chính. Bên cạnh đó, mô hình cũng có thể được đánh giá ở cấp âm vị.

- **Precision (Độ chính xác):** Tỷ lệ dự đoán nhãn “positive” chính xác trên tổng số dự đoán “positive” (trong thí nghiệm này, nhãn 0 được coi là “positive”). Công thức tính:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Trong đó:

- TP = True Positives
- FP = False Positives
- **Recall (Độ bao phủ):** Tỷ lệ số nhãn “positive” thực tế mà mô hình dự đoán được, hữu ích khi muốn giảm thiểu lỗi bị bỏ sót:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Trong đó:

- FN = False Negatives
- **F1-Score:** Được sử dụng khi cần đạt cân bằng giữa Precision và Recall:

$$F1 = 2 \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **PER (Phoneme Error Rate):** Tỷ lệ lỗi ở cấp âm vị, phản ánh hiệu suất nhận dạng âm vị trực tiếp, được tính theo công thức:

$$\text{PER} = \frac{S + D + I}{N}$$

Trong đó:

- S = số âm vị bị thay thế (substitutions)
- D = số âm vị bị xóa (deletions)
- I = số âm vị bị chèn thêm (insertions)
- N = tổng số âm vị trong dãy âm vị gốc

PER có giá trị trong khoảng $[0, 1]$, càng thấp chứng tỏ mô hình nhận dạng âm vị chính xác hơn.

b. Kết quả thực nghiệm

Trong nghiên cứu này, nhóm đã phát triển mô hình với ba phiên bản. Phiên bản đầu tiên PB-MDD-1 chỉ sử dụng bộ dữ liệu L2-ARCTIC với kiến trúc đơn giản. Trong phiên bản thứ 2 PB-MDD-T, nhóm đã tăng cường cho mô-đun nhận diện âm vị bằng một lớp B-LSTM kèm với một lớp Transformer và đã cải thiện hiệu suất đáng kể. Sau đó, nhóm đã bổ sung thêm dữ liệu huấn luyện bằng cách tạo thêm nhãn lỗi cho các tập dữ liệu tiếng Anh bản địa và cải thiện thêm chất lượng mô hình trên thang F1 trong phiên bản thứ 3 PB-MDD-TA.

Phiên bản mô hình	PER (%)	Precision (%)	Recall (%)	F1 score (%)
PB-MDD-1	15.13	53.41	39.47	45.39
PB-MDD-T	15.04	55.57	42.55	48.19
PB-MDD-TA	15.42	51.64	54.97	53.23

Bảng 2: Kết quả kiểm tra qua các phiên bản mô hình được phát triển

Nhóm nhận thấy mô-đun phát hiện lỗi phát âm đã cải thiện 3% khi mô-đun dự đoán âm vị được tăng cường, do cả 2 mô-đun này cùng sử dụng chung đầu vào từ mô-đun mã hóa âm thanh wav2vec2. Điều này cho thấy mô-đun dự đoán âm vị đóng vai trò quan trọng trong việc cập nhật trọng số trong mô-đun mã hóa âm thanh.

Bên cạnh đó, nhóm cũng so sánh kiến trúc mô hình xây dựng được với một số kiến trúc MDD đã được phát triển ở thời điểm hiện tại với cùng tập dữ liệu kiểm tra đã được nêu trong phần trước. Kết quả mô hình đứng thứ 3 so với các mô hình đã tìm được. Ưu điểm của mô hình là có cấu trúc đơn giản hơn với độ chính xác đáng kể gần sát so với các mô hình hiện tại.

Mô hình	Precision (%)	Recall (%)	F1 score (%)
GOP [4]	69.97	32.54	44.42
CNN-RNN-CTC [12]	34.70	74.19	47.28
PB-MDD-TA	51.64	54.97	53.23
PEPPANET [18]	51.38	64.53	56.81
PG-MDD [5]	60.15	60.06	60.10


Bảng 3: So sánh kết quả kiểm tra của mô hình PB-MDD-TA với các mô hình hiện tại

Để mô hình có thể áp dụng hiệu quả hơn trong môi trường tiếng Việt, nhóm đã huấn luyện lại mô hình với phương pháp và cấu hình mô hình tương tự cùng với trọng số nhân 0 là 1.5, sử dụng bộ dữ liệu nói tiếng Anh từ học viên Việt Nam VieSpeechIELTS và tăng cường các bộ dữ liệu TIMIT, SpeechOcean762 và MozillaCommonVoice sử dụng bảng phân bố lỗi thu được của bộ dữ liệu này. Kết quả mô hình đạt 49.17% với chỉ số F1-score, 53,04% với chỉ số Precision và 45.82% với chỉ số Recall.

3.4 Xây dựng hệ thống giao diện

3.4.1 Luồng yêu cầu và xử lý chính

a. Tổng quan hệ thống



Hình 23: Luồng xử lý hệ thống

Kiến trúc hệ thống được thiết kế theo mô hình máy khách-máy chủ tách rời, chia làm hai bộ phận tính toán chính: máy chủ và khối thực thi mô hình. Để đảm bảo hệ thống ổn định và đáp ứng tốt trong quá trình tính toán nặng nề, hệ thống tận dụng giao tiếp không đồng bộ thông qua hàng đợi tin nhắn (Redis).

b. Luồng vận hành

Hệ thống được thiết kế để phục vụ hai nhóm đối tượng chính với các quyền hạn khác nhau, nhưng cùng chia sẻ nền tảng xử lý cốt lõi:

Người dùng truy cập giao diện thực thi mô hình thông qua một trang web và đăng tải âm thanh và nội dung tương

ứng. Yêu cầu được gửi đến cổng FastAPI. Để ngăn máy chủ web không bị đơ trong lúc tính toán, FastAPI không xử lý âm thanh trực tiếp. Thay vào đó, nó đóng vai trò như nhà phát hành, đẩy tác vụ suy luận vào hàng đợi Redis. Khối thực thi mô hình vận hành như một công nhân liên tục nhận lấy công việc từ hàng đợi. Khi nhận được công việc, dữ liệu thông qua ba luồng chính:

- **Tiền xử lý:** Âm thanh thô được tiền xử lý và biến đổi thành dạng mà mô hình có thể sử dụng.
- **Mô hình phát hiện lỗi phát âm:** Mô hình phân tích âm thanh đã được định dạng từ trước.
- **Hậu xử lý:** Đầu ra của mô hình được biến đổi thành dạng có thể đọc được

Kết quả sau khi được xử lý được đưa trở lại máy chủ thông qua Redis, nhận lại bởi FastAPI, và hiển thị cho người dùng trên giao diện thực thi mô hình.

c. Luồng quản trị và giám sát


Quản trị viên có thể tương tác với giao diện giám sát để xem hiệu quả mô hình, số liệu hệ thống, và hoạt động người dùng. FastAPI xử lý các yêu cầu này bằng cách truy vấn dữ liệu trên cơ sở dữ liệu MySQL, ví dụ như độ dài âm thanh trung bình và độ dài văn bản trung bình, và hiển thị thông tin cho quản trị viên thông qua bảng thống kê.

d. Luồng mô hình AI xử lý âm thanh

Người dùng truy cập trang web và cung cấp đoạn âm thanh và văn bản tương ứng. Khi nhận được dữ liệu, hệ thống sẽ tiến hành làm sạch văn bản, sau đó đối chiếu với từ điển CMU. Nếu như không có trong từ điển, kết quả sẽ trả về là “Bad token input”. Nếu có, hệ thống thực hiện căn chỉnh âm vị: ánh xạ từng từ sang chuỗi âm vị chuẩn. Các âm vị này sau đó được chuyển đổi thành chuỗi số định danh thông qua bộ mã hóa, tạo thành nhãn đúng cho mô hình.

Âm thanh gốc sẽ được biến đổi về tần số tiêu chuẩn là 16kHz, cùng với các chuỗi số định danh, và biến đổi thành dạng sóng, cùng với chuỗi số định danh được đưa vào hệ thống AI. Kết quả thô sau khi đưa vào hệ thống AI sẽ được căn chỉnh và đóng gói, lấy được xác suất cũng như kết quả phân tích âm vị. Toàn bộ kết quả được lưu vào file JSON và lưu trữ trong cơ sở dữ liệu MySQL.

Phần giao diện web đóng vai trò cầu nối trực tiếp giữa người dùng và hệ thống. Tại đây, kết quả phân tích phát âm được hiển thị rõ ràng và sinh động, đi kèm với số điểm đạt được cũng như so sánh chi tiết âm vị người dùng phát âm và âm vị chuẩn. Người dùng có thể dễ dàng kiểm tra lỗi sai hoặc lưu lại kết quả để phân tích sâu hơn và cải thiện phát âm.




Luồng mô hình xử lý dữ liệu âm thanh và văn bản

3.4.2 Phân tích thiết kế

a. Xác định yêu cầu

Mục đích của hệ thống: Phát triển một ứng dụng web giúp người dùng phân tích lỗi phát âm và cho phép quản trị viên kiểm tra hiệu quả mô hình và thống kê.

Phạm vi hệ thống:



Hình 24: Sơ đồ phạm vi hệ thống

Giới thiệu hệ thống:

Đây là hệ thống trung tâm cho phép người dùng có thể phân tích phát âm của họ. Thêm vào đó, quản trị viên có thể xem bảng thống kê để kiểm tra hiệu quả mô hình và hoạt động người dùng. Cụ thể:

- **Khách**

- Có thể đăng tải, phân tích bản ghi âm thanh.
- Có thể kiểm tra kết quả phân tích phát âm.

- **Quản trị viên**


- Thực hiện chức năng giống khách.
- Có thể đăng nhập bằng tài khoản quản trị viên.
- Có thể truy cập bảng thống kê để theo dõi hiệu quả mô hình, hoạt động người dùng và số liệu hệ thống.

- **Xử lý âm thanh**

- Logic xử lý âm thanh chính của hệ thống.
- **Hiển thị thông kê**
 - Nơi mà thông tin về âm thanh, nội dung, hoạt động người dùng, và sức khỏe mô hình được hiển thị.
- **Cơ sở dữ liệu**
 - Nơi lưu trữ thông tin chính của hệ thống như là tài khoản quản trị viên, chi tiết âm vị và kết quả phân tích.

Mô tả yêu cầu

- **Yêu cầu chức năng**
 - Hệ thống cho phép người dùng đăng tải file âm thanh hoặc ghi âm trực tiếp trên hệ thống.
 - Hệ thống cho phép người dùng nhập nội dung tương ứng với âm thanh đầu vào để phân tích.
 - Hệ thống hiển thị kết quả phân tích phát âm cho người dùng.
 - Hệ thống cho phép quản trị viên đăng nhập bằng tài khoản quản trị viên để truy cập bảng thống kê.
- **Yêu cầu phi chức năng**
 - Hệ thống phải đảm bảo tốc độ xử lý và phân tích nhanh, đồng thời cung cấp giao diện thân thiện.
 - Hệ thống phải đảm bảo dữ liệu được bảo mật và toàn vẹn.
 - Hệ thống phải đảm bảo khả năng mở rộng trong tương lai.
- **Thông tin các đối tượng cần được xử lý, quản lý**
 - **Thông tin người dùng:** id, username, password.
 - **Tác vụ phân tích:** id, job_id, sentence, sentence_length, submit_time, audio_blob, audio_length_sec, audio_size_kb.
 - **Kết quả phân tích:** result_json.
 - **Chi tiết âm vị:** id, prediction_id, canonical_id, canonical_text, decoded_text, word, sentence, phone_score, error_prob, t1_likelihood, t2_likelihood, t3_likelihood, t1_likelihood_phone, t2_likelihood_phone, t3_likelihood_phone, g, op.
- **Relationship**
 - Một người dùng có thể đăng nhiều tác vụ phân tích, và mỗi tác vụ phân tích liên quan đến đúng một người dùng.
 - Mỗi tác vụ phân tích chỉ có một kết quả phân tích, và mỗi kết quả phân tích tương ứng với đúng một tác vụ phân tích.
 - Một kết quả phân tích có thể chứa nhiều chi tiết âm vị, và mỗi chi tiết âm vị thuộc về đúng một kết quả phân tích.
 - Một người dùng có thể xem kết quả cuối cùng thông qua cặp âm thanh–nội dung đã được đăng.



Hình 25: Biểu đồ use case tổng quát

b. Phân tích thiết kế giải pháp

Biểu đồ Usecase tổng quan

Các use case chính:

- **Đăng nhập:** Cho phép quản trị viên đăng nhập vào hệ thống
- **Xem thống kê:** Cho phép quản trị viên kiểm tra chi tiết âm vị, thông tin âm thanh và văn bản, cũng như hiệu quả mô hình
- **Phân tích phát âm:** Cho phép người dùng phân tích âm thanh đầu vào và phát hiện ra được các lỗi phát âm, cũng như là xem điểm số cuối cùng
- **Cung cấp âm thanh:** Cho phép người dùng cung cấp âm thanh đầu vào
- **Đăng âm thanh có sẵn:** Kế thừa từ Use case Cung cấp âm thanh, cho phép người dùng có thể đăng âm thanh có sẵn từ máy tính lên hệ thống
- **Ghi âm:** Kế thừa từ Use case Cung cấp âm thanh, cho phép người dùng có thể ghi âm trực tiếp ở trên hệ thống.
- **Nhập văn bản:** Cho phép người dùng nhập văn bản đầu vào tương ứng với nội dung âm thanh
- **Xem kết quả:** Cho phép người dùng kiểm tra kết quả phát âm và điểm số cuối cùng

Các kịch bản:

Kịch bản xem thống kê và hiệu quả mô hình

Kịch bản	Xem thống kê và hiệu quả mô hình																																			
Actor	Quản trị viên																																			
Pre-condition	Quản trị viên có tài khoản và đăng nhập thành công																																			
Post-condition	Bảng thống kê được hiển thị trên giao diện																																			
Main Events																																				
1.	Quản trị viên đăng nhập vào hệ thống.																																			
2.	Hệ thống hiển thị giao diện đăng nhập.																																			
3.	Quản trị viên nhập tài khoản và mật khẩu. Ngoại lệ đăng nhập không thành công: Nếu tên tài khoản hoặc mật khẩu sai, thông báo lỗi hiện lên và quản trị viên nhập lại. Hệ thống kiểm tra thông tin đăng nhập: • Nếu đúng, hiển thị bảng thống kê. • Nếu sai, hiển thị thông báo lỗi.																																			
4.	Bảng thống kê hiển thị thông tin âm thanh và hiệu quả mô hình: <table><tr><th>Average Audio Duration (sec)</th><th>Avg Audio Size (KB)</th><th colspan="3">Avg Sentence Length</th></tr><tr><td>5.5</td><td>171.85</td><td colspan="3">25.46</td></tr></table> <table><tr><th>Canonical</th><th>ERROR > 0.7</th><th>ERROR < 0.7</th><th colspan="3">OPS breakdown</th><th>Top 3 Pre-dictions (PROB COUNT)</th></tr><tr><td>AA</td><td>7</td><td>20</td><td>M 20</td><td>D 2</td><td>I 0</td><td>AA 0.96 20 AO 0.80 2 - 0.00 2</td></tr><tr><td>AE</td><td>10</td><td>20</td><td>M 18</td><td>D 9</td><td>I 2</td><td>AE 0.92 18 IH 0.47 5 AH 0.72 4</td></tr></table>					Average Audio Duration (sec)	Avg Audio Size (KB)	Avg Sentence Length			5.5	171.85	25.46			Canonical	ERROR > 0.7	ERROR < 0.7	OPS breakdown			Top 3 Pre-dictions (PROB COUNT)	AA	7	20	M 20	D 2	I 0	AA 0.96 20 AO 0.80 2 - 0.00 2	AE	10	20	M 18	D 9	I 2	AE 0.92 18 IH 0.47 5 AH 0.72 4
Average Audio Duration (sec)	Avg Audio Size (KB)	Avg Sentence Length																																		
5.5	171.85	25.46																																		
Canonical	ERROR > 0.7	ERROR < 0.7	OPS breakdown			Top 3 Pre-dictions (PROB COUNT)																														
AA	7	20	M 20	D 2	I 0	AA 0.96 20 AO 0.80 2 - 0.00 2																														
AE	10	20	M 18	D 9	I 2	AE 0.92 18 IH 0.47 5 AH 0.72 4																														

Kịch bản phân tích âm thanh


Kịch bản	Phân tích âm thanh
Actor	Quản trị viên, khách
Pre-condition	Người dùng đã truy cập vào trang web phân tích ghi âm
Post-condition	Kết quả hiển thị trên hệ thống

Main Events	
1.	Người dùng truy cập vào hệ thống.
2.	Hệ thống hiển thị giao diện với hai dòng (dòng nhập tên tài khoản và dòng nhập mật khẩu), một nút đăng nhập và một link vào chế độ khách.
3.	Người dùng bấm vào chế độ khách.
4.	Hệ thống chuyển sang giao diện với một dòng nhập nội dung, một nút để đăng tải âm thanh, một nút để ghi âm và một nút để xác nhận.
5.	Người dùng nhập nội dung và ghi âm hoặc đăng tải âm thanh có sẵn. Ngoại lệ âm thanh không hợp lệ: Nếu âm thanh được đăng tải có tần số lấy mẫu lớn hơn 16kHz, hệ thống hiển thị thông báo lỗi và người dùng phải đăng tải lại. • Nếu tần số lấy mẫu nhỏ hơn hoặc bằng 16kHz, người dùng có thể nhấn nút xác nhận và kết quả sẽ hiển thị trên hệ thống. • Nếu không, hệ thống hiển thị thông báo lỗi và người dùng phải đăng lại. Ngoại lệ không có âm thanh: Nếu người dùng không cung cấp âm thanh, nút xác nhận sẽ không thể nhấn.
6.	Kết quả về điểm số cũng như âm vị sẽ hiển thị trên hệ thống Ngoại lệ từ không có trong từ điển: Nếu như nội dung văn bản không chứa từ nào có trong từ điển, kết quả hệ thống sẽ trả về “Bad token input”.

3.4.3. User interface (UI)

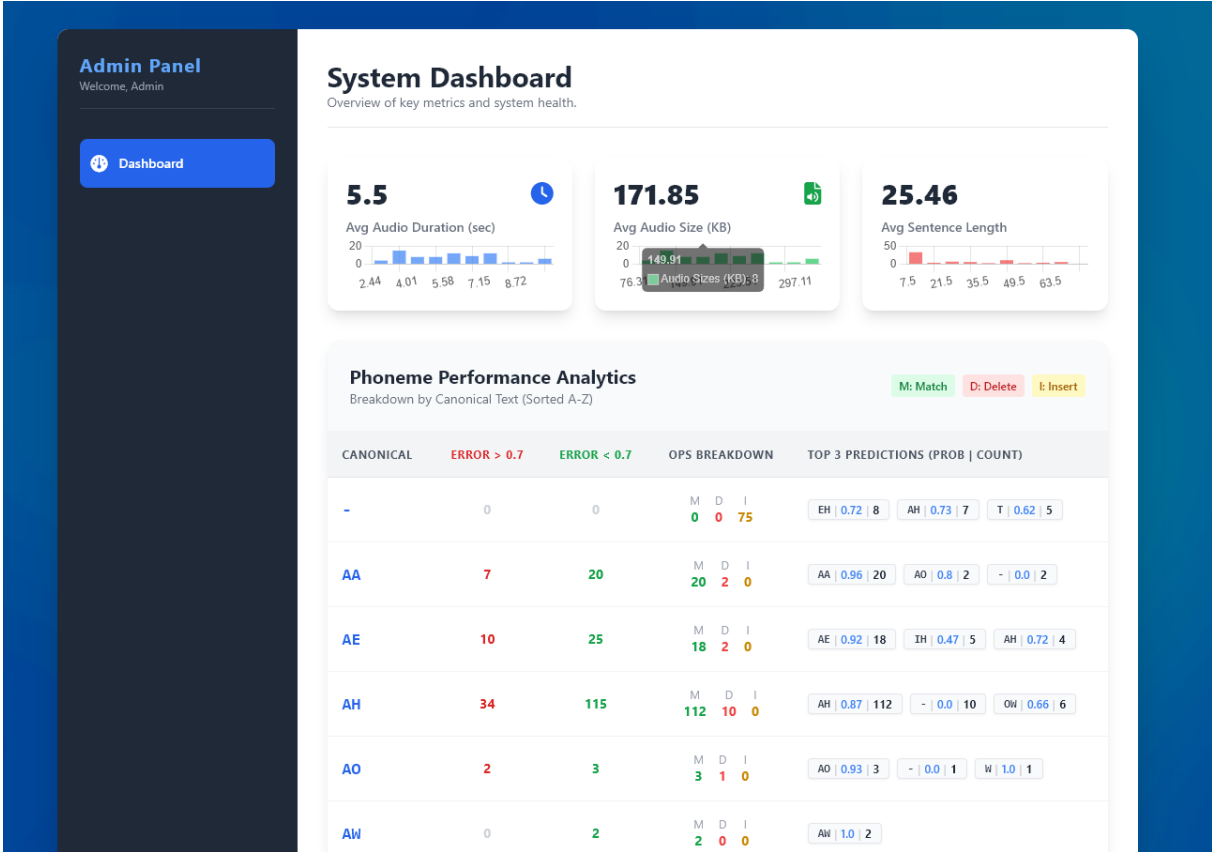
Giao diện người dùng của hệ thống được thiết kế theo hướng tối giản và hiện đại, nhằm tối ưu hóa trải nghiệm luyện tập phát âm của người học cũng như hỗ trợ quản trị viên theo dõi hiệu suất của mô hình AI. Các chức năng và màn hình chính bao gồm:

Giao diện đăng nhập (Login interface): Người dùng khi truy cập hệ thống sẽ được điều đến trang đăng nhập này. Quản trị viên có thể nhập thông tin tài khoản và mật khẩu để đăng nhập và truy cập Bảng điều khiển quản trị. Người dùng cũng có thể truy cập chế độ khách thông qua liên kết ở dưới nút đăng nhập và được điều hướng đến Giao diện nhập liệu và thu âm.



Hình 26: Giao diện đăng nhập


Bảng điều khiển quản trị (System Dashboard): Cung cấp cái nhìn tổng quan về sức khỏe và các chỉ số hoạt động của hệ thống dành cho người quản trị. Giao diện hiển thị trực quan các thông số thống kê như thời lượng âm thanh trung bình (Avg Audio Duration), kích thước tệp trung bình và độ dài câu. Đặc biệt, phần Phoneme Performance Analytics cung cấp bảng phân tích chi tiết hiệu suất của từng âm vị (phoneme), so sánh giữa ký tự chuẩn (Canonical) và các lỗi thường gặp (xóa, chèn, hoặc sai lệch). Các dữ liệu được mã hóa màu sắc giúp quản trị viên dễ dàng nhận diện các âm vị mà mô hình hoặc người dùng thường xuyên xuyên gặp khó khăn.



Hình 27: Bảng thống kê dữ liệu đầu ra của mô hình

Giao diện nhập liệu và thu âm (Pronunciation Assessment): Được thiết kế để người dùng dễ dàng tương tác với hệ thống. Người dùng có thể nhập đoạn văn bản (Transcript) muốn luyện tập và cung cấp âm thanh đầu vào qua hai phương thức linh hoạt:

- Ghi âm trực tiếp (Record Microphone): Cho phép thu âm ngay trên trình duyệt với các nút điều khiển Start/Stop đơn giản.
- Tải lên tệp âm thanh (Upload WAV): Hỗ trợ người dùng tải lên các tệp ghi âm có sẵn để hệ thống phân tích.



Hình 28: Giao diện nhập âm thanh và câu gốc


Hiển thị kết quả tổng quan: Sau khi phân tích, hệ thống trả về kết quả đánh giá một cách trực quan ngay trên đoạn văn bản gốc. Các từ ngữ được tô màu: Màu xanh (Good) cho phát âm đúng, màu vàng (Close) cho phát âm gần đúng, và màu đỏ (Miss) cho các từ phát âm sai hoặc thiếu. Bên cạnh đó, một biểu đồ dạng tròn hiển thị điểm số tổng thể (ví dụ: 62%) kèm theo nhận xét định tính về mức độ giống người bản xứ, giúp người học nắm bắt được trình độ hiện tại của mình.

The screenshot displays a web-based interface for speech analysis. At the top, there is a 'Transcript' section with a text input field containing the placeholder 'Enter the transcript you want to say'. Below this is the 'AUDIO INPUT' section, which includes two options: 'Record Microphone' with 'Start' and 'Stop' buttons, and 'Upload WAV (Mono, 16k)' with a 'Select File' button. A 'STATUS:' indicator shows 'Analysis Complete'. A large green button labeled 'Submit for Analysis' is positioned below the audio input section. The results section features a legend with three colored dots: green for 'GOOD', yellow for 'CLOSE', and red for 'MISS'. The analyzed text 'apple banana handsome' is shown, with 'apple' and 'handsome' in green and 'banana' in red. A 'Replay Recording' button is located below the text. At the bottom, a summary box contains a sad face emoji, the text 'Almost Correct', and a circular progress indicator showing '62%'. Below the percentage, it says 'You sound 62% like a native speaker!'.

Hình 29: Giao diện kết quả phân tích

Phân tích chi tiết từng từ (Detailed Phoneme Breakdown): Để hỗ trợ người học cải thiện sâu hơn, hệ thống cho phép nhấp vào từng từ cụ thể trong kết quả để xem chi tiết. Một cửa sổ bật lên (popup) sẽ hiển thị:

- Expected Phonemes: Chuỗi âm vị chuẩn của từ đó.
- Word Score: Điểm số cụ thể cho từ được chọn.
- Bảng so sánh âm vị: So sánh chi tiết từng âm tiết giữa âm thanh chuẩn và âm thanh người dùng nói, kèm theo điểm số tin cậy cho từng âm (ví dụ: âm 'HH' đạt 90 điểm, âm 'AE' đạt 55 điểm). Chức năng này giúp người học biết chính xác mình đang sai ở âm tiết nào trong từ.



Hình 30: Tooltip phân tích chi tiết âm vị và điểm số

CHƯƠNG 4. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

4.1 Kết luận

Sự phát triển nhanh chóng của trí tuệ nhân tạo và các kiến trúc học sâu đã mở ra nhiều hướng tiếp cận hiệu quả cho việc tự động hóa một phần quá trình giảng dạy và đánh giá năng lực học ngoại ngữ, nhằm đáp ứng nhu cầu học ngoại ngữ ngày càng gia tăng trong bối cảnh toàn cầu hóa. Đề án này tập trung phân tích những ưu điểm và hạn chế của các mô hình phát hiện và chẩn đoán lỗi phát âm ở mức âm vị (MDD) đã và đang được nghiên cứu trong thời gian gần đây, đồng thời phát triển và triển khai một mô hình MDD hướng tới việc đánh giá chính xác khả năng phát âm tiếng Anh của học viên với ngôn ngữ mẹ đẻ là Tiếng Việt.

Dựa trên các kết quả thực nghiệm thu được, đề án đã đạt được những kết quả chính như sau:

- Nghiên cứu, xây dựng và phát triển một mô hình MDD dựa trên các kiến trúc học máy, học sâu hiện đại như Transformer, kết hợp với kỹ thuật fine-tuning nhằm tận dụng hiệu năng của các mô hình đã được huấn luyện trước.
- Tinh chỉnh mô hình nói trên cho nhóm người học tiếng Anh như ngôn ngữ thứ hai (L2), trong đó tiếng Việt là ngôn ngữ mẹ đẻ, giúp mô hình phản hồi tốt hơn với các đặc trưng và kiểu lỗi phát âm đặc thù của nhóm người học này.
- Triển khai mô hình trên hệ thống đánh giá phát âm thời gian thực, đáp ứng yêu cầu về độ trễ thấp và độ chính xác cao.
- Xây dựng hoàn chỉnh luồng xử lý, lưu trữ và trực quan hóa dữ liệu thu được từ quá trình suy luận của mô hình, phục vụ cho việc đánh giá và cải thiện mô hình trong các nghiên cứu tiếp theo.
- Đề xuất và xác định được một phương án thiết kế kiến trúc giúp cải thiện hiệu năng của hệ thống MDD dựa trên học sâu.

Thông qua các thử nghiệm trên hệ thống, mô hình đã chứng minh được tính hiệu quả cũng như khả năng ứng dụng thực tiễn trong các hệ thống hỗ trợ giảng dạy ngoại ngữ. Đồng thời, kết quả của đề án cũng cung cấp những thông tin có giá trị, phục vụ cho quá trình nghiên cứu và phát triển các hệ thống đánh giá phát âm tự động trong tương lai.

4.2 Hướng phát triển

Cải thiện độ chính xác

- Áp dụng thêm các kỹ thuật khác như bổ sung các mô-đun học máy dựa trên các phương pháp âm học nhằm xử lý dữ liệu đầu vào hoặc tinh chỉnh quy trình hậu xử lý đầu ra của mô hình hiệu quả hơn.
- Thử nghiệm với các bộ mã hóa âm thanh tiên tiến khác như WavLM và các phiên bản khác của Wav2vec 2.0.
- Thu tập và xử lý thêm dữ liệu nhằm nâng cao độ chính xác và khả năng tổng quát của mô hình.

Mở rộng tính năng của hệ thống

- Phát triển và bổ sung thêm các đầu tác vụ khác vào mô hình như nhận dạng và sửa lỗi đánh trọng âm, hay chấm điểm độ lưu loát của học viên.

Triển khai và áp dụng mô hình

- Triển khai mô hình trên một ứng dụng dạy tiếng Anh hoàn chỉnh giúp phục vụ trực tiếp cho người học.
- Mở rộng phạm vi nghiên cứu bằng cách thu tập dữ liệu và áp dụng mô hình cho việc phân tích và phát hiện lỗi phát âm của các ngôn ngữ khác.

Với các hướng phát triển đã đề xuất, hệ thống MDD đã được phát triển trong đồ án có tiềm năng tiếp tục được hoàn thiện cả về mặt học thuật lẫn ứng dụng thực tiễn, hướng tới việc trở thành một thành phần quan trọng trong các nền tảng học ngoại ngữ thông minh dựa trên trí tuệ nhân tạo.

CHƯƠNG 5. PHỤ LỤC

5.1 Phụ lục A: Danh sách các âm vị trong chuẩn ARPABET

Nguyên âm			
Arpabet	IPA	Từ ví dụ	Phiên âm Arpabet
AA	ɑ	balm, bot	B AA M, B AA T
AE	æ	bat	B AE T
AH	ʊ	but	B AH T
AO	ɔ	story	S T AO R IY
AW	aʊ	bout	B AW T
AY	aɪ	bite	B AY T
EH	ɛ	bet	B EH T
ER	ɜː	bird	B ER D
EY	eɪ	bait	B EY T
IH	ɪ	bit	B IH T
IY	i	beat	B IY T
OW	oʊ	boat	B OW T
OY	ɔɪ	boy	B OY
UH	ʊ	book	B UH K
UW	u	boot	B UW T

Phụ âm			
Arpabet	IPA	Từ ví dụ	Phiên âm Arpabet
B	b	buy	B AY
CH	tʃ	china	CH AY N AH
D	d	die	D AY
DH	ð	thy	DH AY
F	f	fight	F AY T
G	g	give	G IH V
HH	h	high	HH AY
JH	dʒ	jive	JH AY V
K	k	kite	K AY T
L	l	lie	L AY
M	m	my	M AY
N	n	nigh	N AY
NG	ŋ	sing	S IH NG
P	p	pie	P AY
R	r	rye	R AY
S	s	sigh	S AY
SH	ʃ	shy	SH AY
T	t	tie	T AY
TH	θ	thigh	TH AY
V	v	vie	V AY
W	w	wise	W AY Z
Y	j	yacht	Y AA T
Z	z	zoo	Z UW
ZH	ʒ	pleasure	P L EH ZH ER

5.2 Phụ lục B: Thuật toán Needleman–Wunsch

Needleman - Wunsch là một thuật toán quy hoạch động được phát triển bởi Saul B. Needleman và Christian D. Wunsch vào năm 1970, dùng trong sinh học với mục đích so sánh hai hoặc nhiều chuỗi protein hoặc nucleotide với nhau nhằm phát hiện đột biến gen. Đây là một trong những ứng dụng đầu tiên của phương pháp quy hoạch động trong lĩnh vực này. Cho tới thời điểm hiện tại, thuật toán Needleman - Wunsch vẫn được sử dụng rộng rãi cho bài toán căn chỉnh toàn cục tối ưu, đặc biệt trong những trường hợp mà chất lượng của căn chỉnh toàn cục là yếu tố quan trọng hàng đầu.

Bài toán căn chỉnh dãy có thể được hiểu là tìm ra một cách sắp xếp tối ưu hai hoặc nhiều dãy ký tự sao cho tối đa hóa số lượng ký tự khớp nhau từ hai dãy và giảm thiểu số ký tự không trùng khớp và những khoảng trống. Mỗi căn chỉnh có thể mang một trong ba giá trị:

- Khớp (Match): Là khi hai ký tự ở vị trí hiện tại được căn chỉnh là tương đương.
- Khác (Mismatch): Là khi hai ký tự ở vị trí hiện tại được căn chỉnh mang giá trị khác nhau.
- Chèn/Xóa (Insertion/Deletion): Là khi một ký tự ở vị trí hiện tại tồn tại trên một chuỗi nhưng không thể căn chỉnh với ký tự nào ở chuỗi còn lại, ngoại trừ ký tự Trống. Tùy theo chuỗi đang xét mà ta có thể gán giá trị "khuyết thiếu" (Deletion) hoặc "chèn vào" (Insertion)

Dựa trên mục tiêu này, thuật toán thực hiện căn chỉnh bằng cách sử dụng một hệ thống tính điểm, trong đó có phần thưởng cho các cặp khớp nhau và hình phạt cho các trường hợp không khớp và các khoảng trống.

Trong bài toán căn chỉnh các chuỗi DNA, thay vì liệt kê ra tất cả các căn chỉnh có thể xảy ra và chấm điểm cho tất cả các khả năng, thuật toán này khởi tạo ma trận tương tác giữa hai chuỗi và tính toán số điểm tương tác của các phần tử của chúng dựa trên quy luật sau:

Gọi hai chuỗi ký tự cần căn chỉnh là X và Y , với độ dài lần lượt là M, N . Ta có thể xây dựng ma trận tương tác với kích thước $M \times N$. Để tính điểm tương tác, ta sử dụng hàm:

$$F(i, j) = \max \begin{cases} F(i-1, j-1) + s(x_i, y_j), \\ F(i-1, j) + d, \\ F(i, j-1) + d \end{cases} \quad (62)$$

Với:

$$s(x_i, y_j) = \begin{cases} +1, & \text{if } x_i = y_j \\ -1, & \text{if } x_i \neq y_j \end{cases} \quad (63)$$

Trong đó:

- $F(i, j)$ là số điểm căn chỉnh tối ưu giữa hai ký tự tại tọa độ (i, j) trong ma trận tương tác
- $s(x_i, y_j)$ là hàm chấm điểm khi so sánh hai ký tự x_i và y_j
- d là điểm phạt khoảng trống (gap penalty)

Dựa trên hàm trên, ta có thể thiết lập các giá trị biên của ma trận như sau:

$$F(0, 0) = 0, F(i, 0) = i \cdot d, F(0, j) = j \cdot d \quad (64)$$

Vì dụ, để chấm điểm cho hai dãy $X = [G, C]$ và $Y = [G, A]$, ta khởi tạo ma trận:

		G	C
	0	-1	-2
G	-1	z	x
A	-2	y	c

Với $d = -1$, ta có thể tính z :

$$z = \max \begin{cases} 0 + 1 = 1 \\ (-1) + (-1) = (-2) \\ (-1) + (-1) = (-2) \end{cases} = 1 \quad (65)$$

Qua đó tính được các vị trí x, y :

- Với x :

$$x = \max \begin{cases} (-1) + (-1) = (-2) \\ (-2) + (-1) = (-3) \\ (1) + (-1) = (0) \end{cases} = 0 \quad (66)$$

- Với y :

$$y = \max \begin{cases} (-1) + (-1) = (-2) \\ (1) + (-1) = (0) \\ (-2) + (-1) = (-3) \end{cases} = 0 \quad (67)$$

Từ kết quả của x, y , tính được c :

$$c = \max \begin{cases} 1 + (-1) = 0, \\ 0 + (-1) = -1, \\ 0 + (-1) = -1 \end{cases} = 0 \quad (68)$$

Ta có thể cập nhật ma trận:

		G	C
	0	-1	-2
G	-1	1	0
A	-2	0	0

Thực hiện căn chỉnh dãy

Bắt đầu từ ô góc dưới bên phải, ta thực hiện traceback qua các đường đi mà điểm số được tính toán từ ma trận, để xây dựng chuỗi căn chỉnh. Chuỗi căn chỉnh được xác định theo các quy tắc sau:

- Mũi tên chéo (diagonal):** Biểu thị một *match* hoặc *mismatch*; ký tự ở cột và ký tự ở hàng tại ô xuất phát được căn chỉnh với nhau.
- Mũi tên ngang hoặc dọc:** Biểu thị việc chèn khoảng trống (indel):
 - Mũi tên **dọc** căn một khoảng trống “-” với ký tự của hàng (chuỗi bên).

- Mũi tên **ngang** cần một khoảng trống “-” với ký tự của cột (chuỗi trên).
- **Nhiều mũi tên:** Nếu tại một ô có nhiều hướng đi khả thi, chúng đại diện cho nhiều nhánh cần chỉnh. Nếu các nhánh này đều dẫn từ ô góc dưới bên phải đến ô góc trên bên trái, tất cả đều là các cần chỉnh tối ưu. Trong trường hợp này, mỗi nhánh cần được ghi nhận như một ứng viên cần chỉnh riêng biệt.

Như trong ví dụ trên, ta có một hướng cần chỉnh tối đa:

Đường đi từ ô góc dưới bên phải ($F(2,2)$) trở về ô góc trên bên trái ($F(0,0)$) duy nhất đi qua các ô có giá trị:

$$F(2,2) \rightarrow F(1,1) \rightarrow F(0,0)$$

Vậy hướng cần chỉnh tối đa là:

X	G	C
Y	G	A
OP	M	A

Với OP (Operation) tương ứng:

- M: Mismatch
- A: Mismatch/Alternation

Thuật toán có thể được mô hình hóa như trong thuật toán 1.

Algorithm 1 Needleman–Wunsch Global Alignment**Require:** SequenceA, SequenceB, MatchScore, MismatchScore, GapPenalty**Ensure:** Score matrix F and Traceback matrix

```

1:  $m \leftarrow \text{length}(\text{SequenceA})$ 
2:  $n \leftarrow \text{length}(\text{SequenceB})$ 
3: Initialize  $F[0..m, 0..n]$  and Traceback[0..m,0..n]

4: Phase 1: Matrix Initialization
5: for  $i = 0$  to  $m$  do
6:    $F[i, 0] \leftarrow i \cdot \text{GapPenalty}$ 
7:   Traceback[ $i, 0$ ]  $\leftarrow$  "UP"
8: end for
9: for  $j = 0$  to  $n$  do
10:   $F[0, j] \leftarrow j \cdot \text{GapPenalty}$ 
11:  Traceback[0,  $j$ ]  $\leftarrow$  "LEFT"
12: end for
13: Traceback[0, 0]  $\leftarrow$  "DONE"

14: Phase 2: Matrix Filling
15: for  $i = 1$  to  $m$  do
16:   for  $j = 1$  to  $n$  do
17:     if SequenceA[ $i-1$ ] = SequenceB[ $j-1$ ] then
18:       Substitution  $\leftarrow$  MatchScore
19:     else
20:       Substitution  $\leftarrow$  MismatchScore
21:     end if
22:     ScoreDiagonal  $\leftarrow F[i-1, j-1] + \text{Substitution}$ 
23:     ScoreUp  $\leftarrow F[i-1, j] + \text{GapPenalty}$ 
24:     ScoreLeft  $\leftarrow F[i, j-1] + \text{GapPenalty}$ 
25:      $F[i, j] \leftarrow \max(\text{ScoreDiagonal}, \text{ScoreUp}, \text{ScoreLeft})$ 
26:     if  $F[i, j] = \text{ScoreDiagonal}$  then
27:       Traceback[ $i, j$ ]  $\leftarrow$  "DIAGONAL"
28:     else if  $F[i, j] = \text{ScoreUp}$  then
29:       Traceback[ $i, j$ ]  $\leftarrow$  "UP"
30:     else
31:       Traceback[ $i, j$ ]  $\leftarrow$  "LEFT"
32:     end if
33:   end for
34: end for

35: Phase 3: Traceback / Reconstruct Alignment
36: AlignmentA  $\leftarrow$  ""
37: AlignmentB  $\leftarrow$  ""
38:  $i \leftarrow m, j \leftarrow n$ 
39: while  $i > 0$  OR  $j > 0$  do
40:   if Traceback[ $i, j$ ] = "DIAGONAL" then
41:     AlignmentA  $\leftarrow \text{SequenceA}[i-1] + \text{AlignmentA}$ 
42:     AlignmentB  $\leftarrow \text{SequenceB}[j-1] + \text{AlignmentB}$ 
43:      $i \leftarrow i-1, j \leftarrow j-1$ 
44:   else if Traceback[ $i, j$ ] = "UP" then
45:     AlignmentA  $\leftarrow \text{SequenceA}[i-1] + \text{AlignmentA}$ 
46:     AlignmentB  $\leftarrow \text{""} + \text{AlignmentB}$ 
47:      $i \leftarrow i-1$ 
48:   else if Traceback[ $i, j$ ] = "LEFT" then
49:     AlignmentA  $\leftarrow \text{""} + \text{AlignmentA}$ 
50:     AlignmentB  $\leftarrow \text{SequenceB}[j-1] + \text{AlignmentB}$ 
51:      $j \leftarrow j-1$ 
52:   else
53:     BREAK
54:   end if
55: end while
56: return AlignmentA, AlignmentB, F, Traceback

```

5.3 Phụ lục C: Chi tiết cấu hình của mô hình PB-MDD-TA

```

RLIU_HFWrapper(
  (model): RLIU_Custom(
    (wav2vec2): Wav2Vec2Model(
      (feature_extractor): Wav2Vec2FeatureEncoder(
        (conv_layers): ModuleList(
          (0): Wav2Vec2LayerNormConvLayer(
            (conv): Conv1d(1, 512, kernel_size=(10,), stride=(5,))
            (layer_norm): LayerNorm((512,), eps=1e-05, elementwise_affine=True)
            (activation): GELUActivation()
          )
          (1-4): 4 x Wav2Vec2LayerNormConvLayer(
            (conv): Conv1d(512, 512, kernel_size=(3,), stride=(2,))
            (layer_norm): LayerNorm((512,), eps=1e-05, elementwise_affine=True)
            (activation): GELUActivation()
          )
          (5-6): 2 x Wav2Vec2LayerNormConvLayer(
            (conv): Conv1d(512, 512, kernel_size=(2,), stride=(2,))
            (layer_norm): LayerNorm((512,), eps=1e-05, elementwise_affine=True)
            (activation): GELUActivation()
          )
        )
      )
      (feature_projection): Wav2Vec2FeatureProjection(
        (layer_norm): LayerNorm((512,), eps=1e-05, elementwise_affine=True)
        (projection): Linear(in_features=512, out_features=1024, bias=True)
        (dropout): Dropout(p=0.1, inplace=False)
      )
      (encoder): Wav2Vec2EncoderStableLayerNorm(
        (pos_conv_embed): Wav2Vec2PositionalConvEmbedding(
          (conv): ParametrizedConv1d(
            1024, 1024, kernel_size=(128,), stride=(1,), padding=(64,), groups=16
          )
          (parametrizations): ModuleDict(
            (weight): ParametrizationList(
              (0): _WeightNorm()
            )
          )
        )
        (padding): Wav2Vec2SamePadLayer()
        (activation): GELUActivation()
      )
      (layer_norm): LayerNorm((1024,), eps=1e-05, elementwise_affine=True)
    )
  )

```

```

(dropout): Dropout(p=0.1, inplace=False)
(layers): ModuleList(
  (0-23): 24 x Wav2Vec2EncoderLayerStableLayerNorm(
    (attention): Wav2Vec2Attention(
      (k_proj): Linear(in_features=1024, out_features=1024, bias=True)
      (v_proj): Linear(in_features=1024, out_features=1024, bias=True)
      (q_proj): Linear(in_features=1024, out_features=1024, bias=True)
      (out_proj): Linear(in_features=1024, out_features=1024, bias=True)
    )
    (dropout): Dropout(p=0.1, inplace=False)
    (layer_norm): LayerNorm((1024,), eps=1e-05, elementwise_affine=True)
    (feed_forward): Wav2Vec2FeedForward(
      (intermediate_dropout): Dropout(p=0.0, inplace=False)
      (intermediate_dense): Linear(in_features=1024, out_features=4096, bias=True)
      (intermediate_act_fn): GELUActivation()
      (output_dense): Linear(in_features=4096, out_features=1024, bias=True)
      (output_dropout): Dropout(p=0.1, inplace=False)
    )
    (final_layer_norm): LayerNorm((1024,), eps=1e-05, elementwise_affine=True)
  )
)
)
)
(post_w2v2): Sequential(
  (0): Linear(in_features=1024, out_features=1024, bias=True)
  (1): LayerNorm((1024,), eps=1e-05, elementwise_affine=True)
  (2): GELU(approximate='none')
  (3): Dropout(p=0.3, inplace=False)
)
(rnn): LSTM(1024, 512, num_layers=2, batch_first=True, dropout=0.2, bidirectional=True)
(refiner): TransformerEncoder(
  (layers): ModuleList(
    (0): TransformerEncoderLayer(
      (self_attn): MultiheadAttention(
        (out_proj): NonDynamicallyQuantizableLinear(in_features=1024, out_features=1024, bias=
      )
      (linear1): Linear(in_features=1024, out_features=2048, bias=True)
      (dropout): Dropout(p=0.3, inplace=False)
      (linear2): Linear(in_features=2048, out_features=1024, bias=True)
      (norm1): LayerNorm((1024,), eps=1e-05, elementwise_affine=True)
      (norm2): LayerNorm((1024,), eps=1e-05, elementwise_affine=True)
      (dropout1): Dropout(p=0.3, inplace=False)

```

```

        (dropout2): Dropout(p=0.3, inplace=False)
    )
)
(phone_classifier): Linear(in_features=1024, out_features=41, bias=True)
(canonical_embedding): Embedding(42, 1024, padding_idx=41)
(compare_attention): MultiheadAttention(
  (out_proj): NonDynamicallyQuantizableLinear(in_features=1024, out_features=1024, bias=True)
)
(error_classifier): Sequential(
  (0): Linear(in_features=2048, out_features=512, bias=True)
  (1): GELU(approximate='none')
  (2): Dropout(p=0.2, inplace=False)
  (3): Linear(in_features=512, out_features=128, bias=True)
  (4): GELU(approximate='none')
  (5): Linear(in_features=128, out_features=2, bias=True)
)
)
(ctc_loss): CTCLoss()
(nll_loss): NLLLoss()
)

```

TÀI LIỆU THAM KHẢO

- [1] Zhang, L., Zhao, Z., Ma, C., Shan, L., Sun, H., Jiang, L., Deng, S., Gao, C.: End-to-End Automatic Pronunciation Error Detection Based on Improved Hybrid CTC/Attention Architecture. *Sensors*, 20(7):1809 (2020). doi:10.3390/s20071809. <https://www.mdpi.com/1424-8220/20/7/1809>
- [2] El Kheir, Y., Ali, A., Chowdhury, S. A.: Automatic Pronunciation Assessment - A Review. In: *Findings of the Association for Computational Linguistics: EMNLP 2023*, pp. 8304–8324. Association for Computational Linguistics, Singapore (2023). doi:10.18653/v1/2023.findings-emnlp.557.
- [3] Avery, P., Ehrlich, S.: Teaching American English Pronunciation. Oxford University Press (1992).
- [4] Witt, S.M., Young, S.J.: Phone-level pronunciation scoring and assessment for interactive language learning. *Speech Communication*, 30(2–3):95–108 (2000). doi:10.1016/S0167-6393(99)00044-8
- [5] Lin, M.-S., Yan, B.-C., Lo, T.-H., Wang, H.-W., He, Y.-Y., Chao, W.-C., Chen, B.: PG-MDD: Prompt-Guided Mispronunciation Detection and Diagnosis Leveraging Articulatory Features. In: *2024 Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*, pp. 1–6 (2024). doi:10.1109/APSIPAASC63619.2025.10849000
- [6] Shi, J., Huo, N., Jin, Q.: Context-Aware Goodness of Pronunciation for Computer-Assisted Pronunciation Training. In: *Proceedings of Interspeech 2020*, pp. 3057–3061 (2020). doi:10.21437/Interspeech.2020-2953
- [7] Graves, A., Fernández, S., Gomez, F., Schmidhuber, J.: Connectionist Temporal Classification: Labelling Unsegmented Sequence Data with Recurrent Neural Networks. In: *Proceedings of the 23rd ICML*, pp. 369–376 (2006). doi:10.1145/1143844.1143891
- [8] Baevski, A., Zhou, H., Mohamed, A., Auli, M.: wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations. arXiv preprint arXiv:2006.11477 (2020). doi:10.48550/arXiv.2006.11477
- [9] You, Z., Nijat, M., Shi, Y., Chen, C.: Zero-shot Mispronunciation Detection by Knowledge-based Data Augmentation. In: *Proceedings of the 26th Conference of O-COCOSDA*, (2023). doi:10.1109/O-COCOSDA60357.2023.10482946
- [10] Zhou, X., Lian, J., Cho, C.J., Prabhune, T., Li, S., Li, W., Ortiz, R., Ezzes, Z., Vonk, J., Morin, B., Bogley, R., Wauters, L., Miller, Z., Gorno-Tempini, M., Anumanchipalli, G.: Towards Accurate Phonetic Error Detection Through Phoneme Similarity Modeling. In: *Proceedings of Interspeech 2025*, pp. 4738–4742 (2025). doi:10.21437/Interspeech.2025-2417
- [11] Nguyen, T.V.A., Tran, H.D.: LingWav2Vec2: Linguistic-augmented wav2vec 2.0 for Vietnamese Mispronunciation Detection. In: *Proceedings of Interspeech 2024*, pp. 2355–2359 (2024). doi:10.21437/Interspeech.2024-1569
- [12] Leung, W.-K., Liu, X., Meng, H.: CNN-RNN-CTC Based End-to-End Mispronunciation Detection and Diagnosis. In: *2019 IEEE ICASSP*, pp. 8132–8136 (2019). doi:10.1109/ICASSP.2019.8682654
- [13] Cao, X., Fan, Z., Svendsen, T., Salvi, G.: A Framework for Phoneme-Level Pronunciation Assessment Using CTC. In: *Proceedings of Interspeech 2024*, pp. 302–306 (2024). doi:10.21437/Interspeech.2024-459

- [14] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., Polosukhin, I.: Attention Is All You Need. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30 (2017).
- [15] Bahdanau, D., Cho, K., Bengio, Y.: Neural Machine Translation by Jointly Learning to Align and Translate. arXiv preprint arXiv:1409.0473 (2016).
- [16] S. B. Needleman and C. D. Wunsch, “A general method applicable to the search for similarities in the amino acid sequence of two proteins,” *Journal of Molecular Biology*, vol. 48, no. 3, pp. 443–453, 1970. doi:10.1016/0022-2836(70)90057-4
- [17] A. Zhang, Z. C. Lipton, M. Li, and A. J. Smola, *Dive into Deep Learning*, Cambridge University Press, 2023. Available online: <https://d2l.ai>
- [18] Yan, B.-C., Wang, H.-W., Chen, B.: Peppanet: Effective Mispronunciation Detection and Diagnosis Leveraging Phonetic, Phonological, and Acoustic Cues. In: *Proceedings of the IEEE Spoken Language Technology Workshop (SLT)*, pp. 1045–1051 (2023). doi:10.1109/SLT54892.2023.10022472